

声音分身 VoiceTwin

用你自己的声音，生成新的讲课音频

复刻你的音色、语气和说话节奏 · 支持中文和英文

从下载安装到做出整门课程的完整图文教程（Windows 版）

①

放入讲课视频

以前录好的课程视频、录音
自动切分、识别、过滤

②

训练专属声音

一键训练，自动挑选
最像你的模型、校准语速

③

粘贴讲稿生成

输出音频 + 字幕
可直接剪进课程视频

- ✓ 零基础也能看懂，每一步都有说明
- ✓ 讲稿写法、停顿与读音控制
- ✓ 评估相似度与盲测方法

- ✓ 真实界面截图，照着点就行
- ✓ 剪映配音、替换视频原声
- ✓ 40 多个常见问题的解决办法

目录

写在前面 如何使用这本手册	6
第 1 章 认识声音分身	8
1.1 它能帮你做什么	8
1.2 它是怎么做到"像你"的	8
1.3 实事求是：效果能达到什么程度	9
1.4 整体流程一览	9
1.5 几个常用名词	10
第 2 章 开始之前：检查电脑与准备工具	11
2.1 电脑配置要求	11
2.2 查看显卡型号和显存	11
2.3 查看硬盘剩余空间	12
2.4 更新显卡驱动（建议）	12
2.5 安装解压软件 7-Zip	12
2.6 需要下载的东西清单	13
2.7 准备工作检查表	13
第 3 章 下载与安装	14
3.1 下载声音分身 VoiceTwin	14
3.2 下载 GPT-SoVITS 整合包	15
3.3 解压整合包并放到正确位置	15
3.4 运行安装程序	16
3.5 看懂安装结果（环境检查）	18
3.6 补齐预训练模型（只在提示缺少时才需要）	18
3.7 如何打开"命令提示符"	19
3.8 安装完成后的文件夹说明	20
第 4 章 准备你的讲课素材	21
4.1 什么样的素材最好	21
4.2 需要多少素材	21
4.3 中文和英文素材的比例	22
4.4 整理素材文件夹（实操）	22
4.5 用字幕文件提高准确度（可选）	22
4.6 视频有背景音乐怎么办	23
4.7 素材准备检查表	23
第 5 章 启动程序与界面总览	24
5.1 启动程序	24
5.2 界面总览	25
5.3 关闭程序与下次打开	25

第 6 章 第一步：准备素材	27
6.1 填写声音名称	27
6.2 选择素材	27
6.3 其它选项说明	27
6.4 开始处理并看懂日志	28
6.5 看懂处理结果	30
6.6 需要多长时间	31
第 7 章 校对文字（强烈建议）	32
7.1 为什么要校对	32
7.2 在网页里校对	32
7.3 用 Excel 校对（适合片段很多时）	33
7.4 什么样的片段应该删掉	34
7.5 校对之后	34
第 8 章 第二步：训练你的声音模型	35
8.1 训练前的准备	35
8.2 开始训练	35
8.3 看懂训练日志	36
8.4 训练需要多长时间	37
8.5 "自动挑选最佳模型"和"语速校准"是什么	37
8.6 什么时候需要重新训练	38
8.7 高级：手动设置训练参数	38
第 9 章 第三步：生成讲课音频	39
9.1 准备讲稿	39
9.2 各项设置说明	39
9.3 开始生成	40
9.4 看懂结果表和报告	41
9.5 只重新生成不满意的句子	42
9.6 生成的文件在哪里	42
9.7 生成一整门课程的建议流程	42
第 10 章 讲稿的写法与读音控制	44
10.1 支持的讲稿格式	44
10.2 程序是怎么把讲稿切成句子的	44
10.3 停顿标记：想在哪儿停，停多久	45
10.4 读音纠正词典：解决读错字、多音字、专业术语	46
10.5 用 Markdown 写讲稿	47
10.6 数字、符号和中英混读	48
10.7 按字幕时间轴生成（给现成的视频重新配音）	48
10.8 写出"像你在讲"的讲稿：12 条技巧	49
10.9 一份完整的示例讲稿	49
第 11 章 把生成的音频用到课程视频里	50

11.1 三种常见用法	50
11.2 在剪映里使用生成的音频和字幕	50
11.3 不用剪辑软件：一条命令替换视频的声音	51
11.4 让声音和画面对齐的技巧	51
11.5 声音后期处理建议	52
第 12 章 检验效果：评估相似度与盲测	53
12.1 用"评估相似度"给音频打分	53
12.2 看懂评估结果	54
12.3 用评估功能做对比实验	54
12.4 盲测：让别人来判断	55
12.5 客观看待效果：哪些地方最容易露馅	55
第 13 章 进阶技巧：让声音更像你	57
13.1 提升相似度的方法（按效果从大到小）	57
13.2 指定参考音频：固定你想要的语气	57
13.3 设置文件 config.yaml 详解	58
13.4 可选引擎：Qwen3-TTS 与 IndexTTS	60
13.5 管理多个声音	61
13.6 备份、换电脑和释放硬盘空间	61
13.7 在局域网或手机上使用（注意隐私）	62
第 14 章 命令行用法（选读）	63
14.1 基本用法	63
14.2 全部命令一览	63
14.3 常用参数	64
14.4 实例：一次生成一整门课	65
14.5 用 Excel 校对后同步	65
第 15 章 常见问题与故障排除	66
15.1 安装阶段	66
15.2 启动与网页界面	67
15.3 准备素材阶段	67
15.4 训练阶段	68
15.5 生成阶段	69
15.6 效果问题	70
15.7 其它问题	70
15.8 如何收集信息并求助	71
附录 A 日常使用速查卡	72
A.1 生成一节课（5 步）	72
A.2 讲稿写法速查	72
A.3 质量档位速查	72
A.4 相似度分数速查	73
A.5 什么时候要重新训练	73

A.6 最常用的几条命令 73

附录 B 文件夹和文件说明 74

 B.1 程序文件夹 D:\VoiceTwin 74

 B.2 声音数据文件夹 workspace\我的声音 74

 B.3 GPT-SoVITS 整合包里与你相关的文件 75

附录 C 日志文件说明 76

附录 D 隐私、安全与合规使用 77

 D.1 你的数据留在你的电脑上 77

 D.2 保护好你的声音模型 77

 D.3 合规使用 77

附录 E 版本信息与致谢 78

 E.1 本手册对应的版本 78

 E.2 更新记录 78

 E.3 致谢 78

写在前面

如何使用这本手册

这本手册写给**没有编程基础**的老师。只要会用电脑复制文件、打开网页，就能照着手册一步一步完成：下载程序 → 安装 → 放入你以前录好的讲课视频 → 训练你的专属声音 → 用你的声音生成新的讲课音频和字幕。

阅读建议

- **只想最快用起来**：先看 4 页的《快速上手》（压缩包里双击"使用教程（先看我）.html"，或 Releases 页面的 QuickStart PDF），遇到问题再回来查这本手册。
- **第一次使用**：请按顺序阅读第 1 章到第 9 章，每一步都照做。全程大约需要 2~3 个小时，其中大部分时间是电脑在自动下载和训练，你只需要等待。
- **已经装好、日常使用**：直接看第 9 章《生成讲课音频》和附录 A《日常使用速查卡》。
- **遇到问题**：先看第 15 章《常见问题与故障排除》。
- **想让声音更像**：看第 7 章《校对文字》、第 12 章《检验效果》和第 13 章《进阶技巧》。

手册里的符号和样式

样式	含义
开始准备素材	网页界面 上的按钮 ，用鼠标点击它。
声音名称	网页界面 上的输入框或选项 。
① 准备素材	网页界面顶部的 标签页 ，点击后切换到对应页面。
Enter Ctrl + C	键盘上的 按键 。"+"表示同时按下。
D:\VoiceTwin	电脑上的 文件夹或文件路径 。
voicetwin.bat doctor	需要在黑色的"命令提示符"窗口里 输入的命令 （输入后按 Enter ）。



小技巧

绿色框是能帮你省时间、提升效果的建议。

**注意**

黄色框是容易出错的地方，请仔细看。

**不要这样做**

红色框是会导致失败或者效果变差的操作。

**说明**

蓝色框是补充解释，帮助你理解原理。

关于截图

手册中的截图来自程序的真实界面。截图里的日志时间、数字（例如相似度 0.87）、文件名只是示例，**在你的电脑上会因为你的声音、素材和显卡不同而不同**，这是正常的。黑色的"命令提示符"窗口插图是示意图，文字内容与程序实际输出一致，窗口外观可能与你的电脑略有差异。

适用版本

本手册适用于 **声音分身 VoiceTwin v0.1.2**（Windows 10 / 11）。最新版本和本手册的电子版都可以在这里下载：

<https://github.com/AlienCodes/literate-enigma/releases/latest>

第 1 章

认识声音分身

1.1 它能帮你做什么

声音分身 VoiceTwin 是一个在你自己电脑上运行的"声音克隆"程序。它会仔细"听"你以前录好的讲课视频和录音，学会你的声音；之后你只要把讲稿交给它，它就能用**你的音色、你的语气、你的说话节奏**把讲稿读出来，同时生成对应的字幕文件。



嗓子不舒服也能继续出课

感冒、嗓子哑、需要休息的时候，用讲稿直接生成讲课音频，课程更新不中断。



改一句不用重录整段

录好的课程里讲错了一句话？只生成那一句替换进去，音色和前后完全一致。



中文、英文、中英混说

支持普通话讲解、英文讲解，以及中文里夹英文术语（如"Python 的 list comprehension"）。



自动生成字幕

每次生成都会同时输出 `.srt` 字幕文件，直接导入剪映等剪辑软件，时间轴自动对齐。

1.2 它是怎么做到的"像你"的

听起来"像不像一个人"，主要取决于三件事：**音色**（声音本身的质感）、**语气**（抑扬顿挫、提问和感叹时的语调）、**节奏**（说话快慢、在哪里停顿、停多久）。声音分身把目前最好的开源技术组合起来，分别处理这三件事：

环节	程序做了什么	对应"像"的哪一方面
素材清理	从视频里提取声音；去掉空调、电流等低频嗡嗡声；只有录音明显有噪音时才轻度降噪（降噪过猛会把你的音色一起"削掉"）；统一音量。	音色干净、不失真
智能切分	在你说话自然停顿的地方，把长录音切成 3~12 秒的一句一句；视频有字幕时直接按字幕切，更准确。	训练数据完整准确
语音识别	自动把每一句话识别成文字（中文、英文逐句自动判断），并加上标点。	文字与声音严格对应
质量过滤	剔除识别不可靠、文字对不上、有爆音的片段；用"声纹"比对，自动剔除 不是你本人的声音 （例如学生提问）。	模型只学你的声音
风格分析	统计你的中文和英文语速、逗号 / 句号 / 段落处分别停顿多久、音高和起伏、原始录音的音量，生成你的"说话风格档案"。	节奏、语气

环节	程序做了什么	对应"像"的哪一方面
专属训练	用你的全部素材训练 GPT-SoVITS v2ProPlus 模型（目前开源社区里"用自己的声音训练"最成熟的方案之一，特点是更贴近 整个训练素材的说话风格 ）。	音色 + 语气 + 口音
自动挑模型	训练会保存多个版本。程序留出一小部分 没参加训练 的你的真实录音当"考题"，让每个版本读同样的句子，和你的原声比较，选出总分最高的版本。	选出最像的模型
语速校准	同一句话，比较"模型读用了多久"和"你本人读用了多久"，自动算出语速校正系数。	快慢和你一致
多候选择优	每一句话生成 3~5 个版本，按"声纹相似度 + 语速 / 音高偏差 + （可选）识别错字率"打分，只保留最好的一个；发现漏字、读错会自动重试。	每一句都尽量最像
语气匹配	疑问句用你提问时的录音做参考，感叹句用你感叹时的录音，陈述句用陈述的录音。	语气
自然拼接	句子之间、段落之间按你本人的停顿习惯留空（带自然的长短变化），最终音量调到和你原来的录音一致。	节奏；能无缝剪进旧课程

1.3 实事求是：效果能达到什么程度



实话实说

目前世界上还没有任何技术能保证"任何人、任何一句都 100% 听不出来"。声音分身能做到的是：在素材充足、干净、文字校对过的情况下，生成的声音和你本人**非常接近**，大多数听众很难分辨。


最终效果主要取决于你提供的素材。按影响从大到小：

1. **素材时长**：10 分钟能用，30 分钟以上明显更好，1~3 小时最好。
2. **素材质量**：只有你本人、正常讲课状态、背景安静的录音最好。
3. **文字准确**：识别出的文字校对过，模型就不会学到"口误"。
4. **生成时的质量档位**：正式课程用 `best` 档，每句 5 个候选自动择优。

第 12 章会教你用"评估"功能打分，以及用"盲测"的方法客观地检验效果。

1.4 整体流程一览

整个使用过程分为"安装一次"和"日常使用"两部分：



①②③ 只需要做一次（以后增加了新素材，可以再做一次 ②③ 让声音更像）。之后每次出课，只需要做 ④。

1.5 几个常用名词

名词	意思
素材	你以前录的讲课视频或音频，程序从里面学习你的声音。
片段	程序把长录音切成的一小段一小段（每段 3~12 秒，大多是一句话）。
声音名称	你给这个声音起的名字，例如"我的声音"。一个声音对应一套素材和模型，以后每次使用都选这个名字。
参考音频	程序从你的素材里自动挑出的、最有代表性的几句话。生成时模型会参考它们的语气。
训练	让模型反复"听"你的素材、学习你的声音的过程，需要显卡，耗时较长。
模型	训练的结果，可以理解为"你的声音的数字副本"，保存在 GPT-SoVITS 文件夹里。
生成（合成）	用训练好的模型把文字读出来。
GPT-SoVITS	一个开源的声音克隆项目，声音分身用它来训练和生成声音。
整合包	GPT-SoVITS 官方为 Windows 用户打包好的版本，里面已经装好了所有复杂组件，解压就能用。
显存	显卡自带的内存。训练需要显存，6GB 以上可以训练，越大越快。
声纹相似度	程序用"声纹模型"衡量两段声音像不像同一个人，数字越接近 1 越像（0.86 以上可以认为非常像）。
字幕（srt）	带时间轴的文字文件，剪辑软件可以直接导入，显示在视频下方。

第 2 章

开始之前：检查电脑与准备工具

2.1 电脑配置要求

项目	最低要求	推荐配置
操作系统	Windows 10（64 位）	Windows 10 / 11（64 位）
显卡	NVIDIA 显卡，显存 6GB	NVIDIA RTX 3060 12GB 或更好
内存	16GB	32GB
硬盘	剩余 30GB	剩余 50GB 以上，固态硬盘（SSD）更快
网络	安装和第一次使用时需要下载约 10~15GB 的文件；之后日常使用不需要联网。	



没有 NVIDIA 显卡怎么办？

程序也能运行，但"训练"这一步会非常慢（可能需要几天）。建议找一台有 NVIDIA 显卡的电脑完成训练；训练好之后，生成音频对显卡的要求低很多。AMD 显卡和 Intel 集成显卡目前不支持加速训练。

2.2 查看显卡型号和显存

- 1 同时按下键盘上的 `Ctrl` + `Shift` + `Esc`，打开"任务管理器"。
- 2 如果窗口很小、只有几个程序名，点左下角的 `详细信息`。
- 3 点窗口上方（Windows 11 在左侧）的 `性能`。
- 4 在左侧列表里找到 `GPU 0` 或 `GPU 1`，逐个点开看。
- 5 看右上角的显卡名称，以及下方的 `专用 GPU 内存`：
 - 名称里有 **NVIDIA**（例如 NVIDIA GeForce RTX 3060），并且专用 GPU 内存 $\geq$ **6.0 GB**：✅ 符合要求。
 - 名称是 Intel 或 AMD：这是非 NVIDIA 显卡，训练会很慢，请看上面的黄色提示。

2.3 查看硬盘剩余空间

- 1 双击桌面上的"此电脑"（或按 **Win** + **E** 打开文件资源管理器，点左侧的"此电脑"）。
- 2 在"设备和驱动器"里看每个盘下面的"可用空间"，选一个**可用空间大于 30GB** 的盘。
- 3 本手册统一以 **D 盘** 为例。如果你的电脑没有 D 盘，或 D 盘空间不够，下面所有 **D:** 都换成你选的盘，例如 **E:**。



尽量不要放在 C 盘（系统盘）：C 盘空间一般比较紧张，而且系统文件夹的权限限制可能导致安装失败。

2.4 更新显卡驱动（建议）

显卡驱动太旧，训练时可能会报错。建议更新到最新版本：

- 1 用浏览器打开 NVIDIA 驱动下载页：<https://www.nvidia.cn/drivers/lookup/>
- 2 按你的显卡型号选择（例如：GeForce → GeForce RTX 30 Series → GeForce RTX 3060 → Windows 11），点"查找"。
- 3 下载最新的"Game Ready"或"Studio"驱动，双击安装，一路选"同意并继续" → "精简安装"。
- 4 安装完成后重启电脑。



如果电脑上装了 "NVIDIA App" 或 "GeForce Experience"，也可以直接在里面点"驱动程序" → "检查更新"。

2.5 安装解压软件 7-Zip

GPT-SoVITS 整合包是 **.7z** 格式的压缩包，需要用 7-Zip 解压（免费软件）：

- 1 打开 <https://www.7-zip.org/>
- 2 在页面最上面的下载表格里，点第一行（64-bit Windows x64）对应的 **Download**。
- 3 双击下载好的安装程序（文件名类似 **7z2409-x64.exe**），点 **Install**，完成后点 **Close**。



Windows 11 自带解压 7z 的功能，但遇到大文件时 7-Zip 更稳定、更快，建议还是安装。

2.6 需要下载的东西清单

名称	大小	下载地址 / 说明
声音分身 VoiceTwin	约 7MB	https://github.com/AlienCodes/literate-enigma/releases/latest 下载 <code>VoiceTwin-Windows-v....zip</code> （第 3.1 节）
GPT-SoVITS 整合包	约 5~10GB	GPT-SoVITS 官方文档的下载页（第 3.2 节）
7-Zip	约 2MB	https://www.7-zip.org/ （第 2.5 节）
语音识别模型等	约 3~5GB	第一次使用时程序 自动下载 ，不用手动下载

2.7 准备工作检查表

开始安装前，确认下面每一项都已经完成（可以打印出来逐项打勾）：

- ☐ 电脑是 Windows 10 或 Windows 11（64 位）
- ☐ 有 NVIDIA 显卡，专用 GPU 内存 $\geq 6\text{GB}$ （2.2 节）
- ☐ 选好了一个剩余空间 $\geq 30\text{GB}$ 的盘，下面以 D 盘为例（2.3 节）
- ☐ 显卡驱动已更新（2.4 节，建议）
- ☐ 已安装 7-Zip（2.5 节）
- ☐ 网络通畅，接下来 1 小时左右可以持续下载
- ☐ 准备好了你以前录的讲课视频或录音（第 4 章会详细讲怎么挑选）

第 3 章

下载与安装

这一章完成后，你的电脑上会有两个文件夹：**D:\VoiceTwin**（声音分身）和 **D:\GPT-SoVITS**（整合包），桌面上会出现一个“声音分身 VoiceTwin”图标。整个过程大约 30~60 分钟，主要时间花在下载上。

3.1 下载声音分身 VoiceTwin

- 1 用浏览器（推荐 Edge 或 Chrome）打开：
<https://github.com/AlienCodes/literate-enigma/releases/latest>
- 2 页面上方是版本说明。往下拉，找到 **Assets**（资源）这一栏；如果它是折叠的，点一下把它展开。
- 3 点 **VoiceTwin-Windows-v0.1.2.zip**（版本号可能更高）开始下载。

 不要下载下面的 **Source code (zip)** 和 **Source code (tar.gz)**，那是给开发者的源代码。

- 4 下载完成后，打开“下载”文件夹（浏览器下载列表里点“在文件夹中显示”）。
- 5 在 **VoiceTwin-Windows-v0.1.2.zip** 上点鼠标右键 → 选择 **全部解压缩...**（Windows 11 需要先点 **显示更多选项**）。
- 6 在弹出的窗口里，把“文件将被提取到这个文件夹”下面的路径改成 **D:**，然后点 **提取**。
- 7 打开 D 盘，你会看到一个 **VoiceTwin** 文件夹，也就是 **D:\VoiceTwin**。打开它，确认里面有这些文件：

```
D:\VoiceTwin
├─ install_windows.bat      ← 安装程序（下一步要双击它）
├─ install_windows.ps1
├─ 使用教程（先看我）.html ← 简明网页版教程
├─ README.md
├─ pyproject.toml
├─ docs\                   ← 本手册 PDF 也在这里
└─ voicetwin\              ← 程序本体，不要改动
```



GitHub 在国内有时打开很慢或打不开，可以多刷新几次、换个时间，或者换一个网络（例如手机热点）再试。

3.2 下载 GPT-SoVITS 整合包

GPT-SoVITS 是声音分身用来训练和生成你的声音的核心工具。它的官方团队为 Windows 提供了"整合包"，已经装好了 Python、PyTorch、显卡加速等所有复杂组件。

- 1 打开 GPT-SoVITS 官方文档的整合包下载页（国内用户）：
<https://www.yuque.com/baicaigongchang1145haoyuangong/ib3gle/dkxgpiy9zb96hob4#KTvn0>
 海外用户可以用：<https://huggingface.co/lj1995/GPT-SoVITS-windows-package/tree/main>
- 2 在"整合包"部分找到下载链接，下载**最新版**。怎么判断是不是新版：
 - 文件名里带 **v2pro**（或者比 v2pro 更新的版本号）；
 - 文件名里的日期越新越好（例如 2025 年 6 月以后）；
 - 如果你的显卡是 **RTX 50 系列**（5060/5070/5080/5090），并且页面上有专门标注 50 系的版本（文件名带 **50** 或 **nvidia50** 字样），请选那个。
- 3 整合包有好几个 GB，下载需要一段时间。下载时可以先去做第 4 章的素材整理。

3.3 解压整合包并放到正确位置

- 1 在下载好的 **.7z** 文件上点右键 → **7-Zip** → **提取到"文件名\"**（Windows 11 要先点"显示更多选项"）。解压需要几分钟。
- 2 解压完成后，会得到一个文件夹，名字类似 **GPT-SoVITS-v2pro-20250604**。
- 3 在这个文件夹上点右键 → **重命名**，改成 **GPT-SoVITS**。
- 4 把它**剪切**（**Ctrl** + **X**）到 D 盘根目录后**粘贴**（**Ctrl** + **V**），最终路径是 **D:\GPT-SoVITS**。
- 5 打开 **D:\GPT-SoVITS**，检查是否**直接**能看到下面这些：

```
D:\GPT-SoVITS
├─ go-webui.bat           ← 有它说明位置对了
├─ api_v2.py              ← 声音分身需要用到
├─ runtime\               ← 整合包自带的 Python 环境
├─ GPT_SoVITS\
├─ tools\
└─ .....
```

❌ 常见错误 1：多套了一层文件夹

如果你看到的是 `D:\GPT-SoVITS\GPT-SoVITS-v2pro-2025xxxx\go-webui.bat`，说明多了一层。请打开里面那一层，全选 (`Ctrl + A`) 所有内容，剪切到外面的 `D:\GPT-SoVITS` 里。（安装程序也会尝试自动找到里面那层。）

❌ 常见错误 2：路径里有中文或空格

`D:\GPT-SoVITS` ✓ `D:\新建文件夹\GPT SoVITS` ✗ `C:\Users\张老师\Desktop\GPT-SoVITS` ✗

中文和空格会导致部分组件报错，请一定放在类似 `D:\GPT-SoVITS` 这样简单的路径里。



想确认整合包本身是好的，可以双击 `D:\GPT-SoVITS\go-webui.bat`，如果能打开 GPT-SoVITS 自己的网页界面，说明整合包正常。确认后关掉那个黑色窗口即可（声音分身不需要你手动打开它）。

3.4 运行安装程序

- 1 打开 `D:\VoiceTwin`，双击 `install_windows.bat`。
- 2 如果弹出蓝色窗口 "Windows 已保护你的电脑"：点 `更多信息`，再点 `仍要运行`。
如果 360、火绒等杀毒软件弹出拦截提示，选择 `允许` 或 `信任此程序`。



出现这个提示是因为安装程序是从网上下载的、没有购买微软的签名证书，并不是病毒。安装程序的全部内容都是公开的，可以用记事本打开 `install_windows.ps1` 查看。

- 3 会出现一个黑色窗口，显示安装菜单。输入 `1`，按 `Enter`：

```

Windows PowerShell — 安装程序 (示意)

=====
VoiceTwin 声音分身 安装程序
=====
安装位置: D:\VoiceTwin

请选择安装方式:
  1) 推荐: 安装到 GPT-SoVITS 整合包里 (最省事, 语音识别和训练都用显卡, 不用重复下载 PyTorch)
  2) 独立安装: 创建单独的 Python 虚拟环境 (需要本机已安装 Python 3.10 或 3.11, 适合有经验的用户)
请输入 1 或 2, 然后按回车: 1
  
```

- 4 接着它会让你输入整合包的位置。输入 `D:\GPT-SoVITS`，按 `Enter`：

Windows PowerShell — 安装程序（示意）

请输入 GPT-SoVITS 整合包所在的文件夹路径（打开那个文件夹，里面能看到 go-webui.bat 和 runtime 文件夹）。
小技巧：在文件夹窗口顶部的地址栏点一下，复制路径，再回到这里右键粘贴。
GPT-SoVITS 整合包路径（例如 D:\GPT-SoVITS）：`D:\GPT-SoVITS`

**不想手打路径？**

打开 `D:\GPT-SoVITS` 文件夹 → 点窗口顶部的地址栏（路径会变成蓝色选中状态）→ 按 `Ctrl + C` 复制 → 回到黑色窗口，**点鼠标右键**就能粘贴。

- 5** 等待 3~10 分钟。窗口里会滚动很多英文（这是在下载和安装组件），属于正常现象。**请不要关闭窗口**。过程中会依次出现下面这些步骤标题：

Windows PowerShell — 安装程序（示意）

```
==> 安装 VoiceTwin 到整合包环境 (--no-deps: 不改动整合包原有依赖的版本)
Looking in indexes: https://pypi.tuna.tsinghua.edu.cn/simple
Processing d:\voicetwin
..... (很多英文, 正常现象)
Successfully installed voicetwin-0.1.2
==> 生成配置文件 config.yaml
已生成 D:\VoiceTwin\config.yaml, 按需修改即可。
==> 生成启动脚本 start_webui.bat / voicetwin.bat
已在桌面创建快捷方式「声音分身 VoiceTwin」
==> 检查环境
[✓] Python: 3.x.x (Windows AMD64)
[✓] ffmpeg: D:\GPT-SoVITS\runtime\.....\imageio_ffmpeg\binaries\ffmpeg-....exe
[✓] numpy: 1.26.x
.....
[!] funasr (中文识别, 可选): 未安装
[✓] NVIDIA 显卡: NVIDIA GeForce RTX 3060, 12288 MiB, 5xx.xx
[✓] 引擎 GPT-SoVITS: 就绪 (Python: D:\GPT-SoVITS\runtime\python.exe)
[!] 引擎 Qwen3-TTS: ..... (可选, 不用管)
[!] 引擎 IndexTTS: ..... (可选, 不用管)

安装完成!
- 双击桌面上的「声音分身 VoiceTwin」或本文件夹里的 start_webui.bat 打开网页界面
- 上面的检查如果有 ✗, 请按提示处理 (详见《Windows详细使用教程》的常见问题部分)
按回车键关闭窗口:
```

- 6** 看到 **"安装完成!"** 后，先别急着关，按下一节的方法看一下"检查环境"的结果，然后按 `Enter` 关闭窗口。

- 7** 回到桌面，你会看到新出现的 **"声音分身 VoiceTwin"** 图标，以后双击它就能打开程序。



双击 `install_windows.bat` 后窗口一闪就没了？

在 `install_windows.ps1` 上点右键 → 选择 `使用 PowerShell 运行`。如果仍然不行，请看第 15.1 节。

3.5 看懂安装结果（环境检查）

"检查环境"会逐项列出程序需要的组件。每一行前面有一个符号：

符号	含义	你需要做什么
✓	正常	不用管。
⚠	可选组件没装，或者是提醒	一般不用管。例如"funasr 未安装""demucs 未安装""引擎 Qwen3-TTS""引擎 IndexTTS"都是可选的。
✗	必需的东西有问题	需要处理，见下表。

常见的 ✗ 提示	处理方法
引擎 GPT-SoVITS：缺少预训练模型：…… v2Pro……	整合包版本较早，没有自带 v2Pro 模型。按 3.6 节自动下载。
引擎 GPT-SoVITS：找不到 GPT-SoVITS 目录	整合包路径输错了，或者之后移动过文件夹。重新运行 <code>install_windows.bat</code> ，输入正确路径。
NVIDIA 显卡：没有找到 nvidia-smi	显卡驱动没装好，或者电脑没有 NVIDIA 显卡。按 2.4 节更新驱动。
ffmpeg：找不到 ffmpeg	很少见。重新运行安装程序；仍然不行请看第 15.1 节。

3.6 补齐预训练模型（只在提示缺少时才需要）

较早的整合包没有自带 v2Pro 模型（大约 1~2GB）。声音分身可以自动帮你下载：

- 按 3.7 节的方法，在 `D:\VoiceTwin` 文件夹里打开"命令提示符"。
- 输入下面这行，按 `Enter`：
`voicetwin.bat download-models --source hf-mirror`
- 等待下载完成，看到 "**✓ 已下载 N 个文件**"。
- 再输入 `voicetwin.bat doctor` 按 `Enter`，确认出现 "**✓ 引擎 GPT-SoVITS：就绪**"。

```
● ● ● 命令提示符 (示意)

D:\VoiceTwin>voicetwin.bat download-models --source hf-mirror
21:05:12 | 下载 v2Pro/s2Gv2ProPlus.pth (https://hf-mirror.com) .....
21:05:40 | 下载 v2Pro/s2Dv2ProPlus.pth (https://hf-mirror.com) .....
21:06:02 | 下载 sv/pretrained_eres2netv2w24s4ep4.ckpt (https://hf-mirror.com) .....
✅ 已下载 4 个文件

D:\VoiceTwin>voicetwin.bat doctor
.....
✅ 引擎 GPT-SoVITS: 就绪 (Python: D:\GPT-SoVITS\runtime\python.exe)
```



下载总是失败?

用记事本打开 `D:\VoiceTwin\config.yaml`，找到 `version: v2ProPlus` 这一行，改成 `version: v2`，保存。这样会使用整合包自带的 v2 模型，不需要下载，效果略逊一些。

3.7 如何打开"命令提示符"

大部分操作都在网页界面里完成，但有少数步骤（例如上一节）需要在黑色的"命令提示符"窗口里输入命令。打开方法：

- 1 打开 `D:\VoiceTwin` 文件夹。
- 2 点一下窗口顶部的**地址栏**（显示"此电脑 > 本地磁盘 (D:) > VoiceTwin"的那一栏），里面的文字会变成可编辑的路径。
- 3 把地址栏里的文字删掉，输入 `cmd`，按 `Enter`。
- 4 会弹出一个黑色窗口，第一行显示 `D:\VoiceTwin>`，说明已经位于正确的文件夹，可以输入命令了。



在命令提示符里：输入命令后按 `Enter` 执行；命令运行时不要关窗口；想复制窗口里的文字，用鼠标选中后按 `Enter`（或右键）；想粘贴，点鼠标右键。

3.8 安装完成后的文件夹说明

```
D:\VoiceTwin
├─ start_webui.bat          ← 启动程序（桌面图标指向它）
├─ voicetwin.bat           ← 在命令提示符里使用的命令入口
├─ config.yaml             ← 设置文件（第 13.3 节），可用记事本修改
├─ install_windows.bat     ← 安装程序（重新安装、换整合包路径时再运行）
├─ workspace\              ← 第一次准备素材后自动出现，你的所有数据都在这里
│   └─ 我的声音\
│       ├── outputs\        ← 生成的音频、字幕、报告
│       ├── transcripts.csv  ← 校对表
│       ├── lexicon.txt      ← 读音纠正词典
│       └── .....（附录 B 有完整说明）
```



请不要随意删除 workspace 文件夹

里面保存着你切好的素材、校对结果和生成的音频。想换电脑时，把整个 **D:\VoiceTwin** 和 **D:\GPT-SoVITS** 一起复制过去即可。

第 4 章

准备你的讲课素材

素材是决定"像不像"最重要的因素。程序会自动处理大部分问题，但**放进去的素材越好，出来的声音越像你**。这一章花 10 分钟读完，能少走很多弯路。

4.1 什么样的素材最好

✔ 好素材	✘ 不好的素材
你本人正常讲课的状态，声音自然、有精神	嗓子哑了、感冒、疲惫状态下的录音
背景安静（普通房间、录音间）	全程有背景音乐、空调轰鸣、键盘声很大
用麦克风录的原始音频（wav），或者画质正常的讲课视频	被多次压缩、声音发闷发虚的低质量视频
只有你一个人在说话	多人对话、访谈、大量学生发言
内容丰富：有陈述、有提问、有感叹，语气自然多样	全程念稿、语调平淡；或者全是喊口号式的激动语气
和你以后想生成的内容风格一致（例如都是讲课）	风格完全不同（例如唱歌、配音、朗诵诗歌）

 少量学生提问、偶尔的杂音不用担心：程序会用"声纹"自动识别并剔除不是你本人的片段，也会过滤掉有爆音、识别不清的片段。

4.2 需要多少素材

素材总时长	效果	说明
不到 10 分钟	能用，但一般	音色大致像，语气和节奏不够稳定。程序会给出提示。
10~30 分钟	较好	音色比较像，大部分句子自然。
30 分钟~1 小时	好	音色、语气都明显更像，推荐的起点。
1~3 小时	最好	推荐。语气、节奏、口头习惯都能学到。
3 小时以上	和 3 小时差不多	继续增加收益变小，训练时间变长；优先保证质量而不是数量。



这里说的时长是**你说话的时长**。一节 45 分钟的课，去掉停顿、放 PPT 不说话的时间，实际说话可能只有 30 分钟左右，程序会自动统计给你看。

4.3 中文和英文素材的比例

- **只做中文课**：全部放中文讲课素材即可。中文里夹英文单词（如 Python、list）没有问题。
- **也要做英文课**：请一定放入你**讲英文**的录音，至少 5~10 分钟，越多越好。否则生成的英文会带一点"中文腔"，不像你平时讲英文的样子。
- 程序会分别统计中文、英文素材的分钟数；英文不足 5 分钟时会给出提醒。

4.4 整理素材文件夹（实操）

1 打开 D 盘，在空白处点右键 → **新建** → **文件夹**，命名为 **讲课素材**，也就是 **D:\讲课素材**。

2 把你以前的讲课视频或音频**复制**（不是剪切）到这个文件夹里。支持的格式：

视频	mp4、mov、mkv、avi、flv、webm、wmv、m4v、ts、mts、3gp
音频	wav、mp3、m4a、aac、flac、ogg、opus、wma、amr

3 文件可以放在子文件夹里（例如按学期分），程序会自动找到所有子文件夹里的视频和音频。

4 文件名用什么都可以，建议用有意义的名字，例如 **第1课.mp4**、**第2课.mp4**。

D:\讲课素材

├─ 第1课.mp4

├─ 第1课.srt

← 有字幕的话，和视频同名放在一起（可选，见 4.5 节）

├─ 第2课.mp4

├─ 第3课.mp4

└─ 英文课\

├─ Lesson1.mp4

└─ Lesson2.mp4

4.5 用字幕文件提高准确度（可选）

如果你的视频本来就有字幕文件（**.srt** 或 **.vtt**，比如以前用剪映自动生成并导出的字幕），请把它和视频放在一起，并且**文件名相同**：

- 第1课.mp4 + 第1课.srt 
- 第1课.mp4 + 第1课.zh.srt （也能识别）
- 第1课.mp4 + 字幕1.srt （名字不同，不会被使用）

有字幕时，程序会直接用字幕里的文字和时间轴切分，比语音识别更准确，训练效果更好。没有字幕也完全没关系，程序会自动识别。

 字幕里的文字要和你实际说的话一致。如果字幕是后期重新写过的（和原话差别很大），反而会影响效果，这种情况下不要放字幕。

4.6 视频有背景音乐怎么办

如果只是片头片尾有音乐，不用处理（程序会过滤掉）。如果**全程**都有背景音乐，建议先用 GPT-SoVITS 整合包自带的人声分离工具把人声提取出来：

- 1 双击 `D:\GPT-SoVITS\go-webui.bat`，等浏览器打开 GPT-SoVITS 的界面。
- 2 找到 `UVR5 人声伴奏分离`（通常在第一个标签页"前置数据集获取工具"里），勾选打开它的界面。
- 3 按页面提示选择模型（一般选带 "HP2" 或 "HP5" 的人声模型），输入你的视频 / 音频所在文件夹，指定输出文件夹，开始处理。
- 4 处理完成后，把输出文件夹里**人声（vocal）**的音频文件放进 `D:\讲课素材`，代替原来有音乐的视频。

 GPT-SoVITS 界面会随版本更新变化，具体按钮名称以它的界面为准。声音分身里也有"视频有背景音乐（去除背景音乐）"选项，但需要额外安装 demucs 组件，普通用户推荐用上面的 UVR5 方法。

4.7 素材准备检查表

- ☐ 素材放在 `D:\讲课素材`（路径尽量简单）
- ☐ 总共有 30 分钟以上你说话的内容（1~3 小时最好）
- ☐ 是你正常讲课状态的录音，**没有嗓子哑之后的录音**
- ☐ 要做英文课的话，放入了至少 5~10 分钟你讲英文的录音
- ☐ 有字幕的话，字幕和视频同名放在一起
- ☐ 全程有背景音乐的**视频**已经做过人声分离（或者不放）

第 5 章

启动程序与界面总览

5.1 启动程序

- 1 双击桌面上的 "声音分身 VoiceTwin" 图标 (或者 `D:\VoiceTwin\start_webui.bat`)。
- 2 会出现一个黑色窗口，显示 "正在启动声音分身……"：

```
● ● ● 声音分身 (示意)

正在启动声音分身，浏览器会自动打开 http://127.0.0.1:7860 ，使用期间请不要关闭本窗口.....
21:30:02 | 网页界面: http://127.0.0.1:7860
Running on local URL: http://127.0.0.1:7860
```

 **使用期间不要关闭这个黑色窗口。**它就是程序本身，关掉它网页就不能用了。可以把它最小化。

- 3 等 10~30 秒，浏览器会自动打开程序界面，地址是 <http://127.0.0.1:7860>。如果浏览器没有自动打开，就自己打开浏览器，在地址栏输入 `127.0.0.1:7860`，按 `Enter`。

 这个网页只在你自己的电脑上运行 (127.0.0.1 表示 "本机")，不需要注册、登录，你的声音和素材也不会上传到任何地方。

5.2 界面总览



图 5-1 声音分身的网页界面（① 准备素材 页面，已填好声音名称和素材文件夹）

界面从上到下分为三部分：

位置	作用
最上面：声音名称	选择或新建一个"声音"。第一次使用时直接输入名字（例如"我的声音"）；以后点右边的小三角从列表里选。旁边的 刷新 用来刷新列表。 所有标签页都使用这里选中的声音。
中间：五个标签页	① 准备素材 放入讲课视频，自动切分、识别、过滤（第 6、7 章） ② 训练模型 训练你的专属声音模型（第 8 章） ③ 生成讲课音频 粘贴讲稿，生成音频和字幕（第 9 章） ④ 评估相似度 给任意一段音频打分，看有多像你（第 12 章） 环境检查 检查显卡、模型等是否正常（与安装时的检查相同）
下面：当前标签页的内容	各种输入框、按钮和运行日志。

第一次使用请严格按 ① → ② → ③ 的顺序操作。训练好之后，日常只需要用 ③。

5.3 关闭程序与下次打开

- **关闭：**先关浏览器页面，再关掉黑色窗口（点右上角 ×）。正在准备素材、训练或生成时不要关。

- **下次打开：**双击桌面图标 → 在 声音名称 里选"我的声音" → 直接去需要的标签页。之前准备的素材、训练的模型都会自动保留。
- **电脑重启后：**和"下次打开"一样，不需要重新安装。

第 6 章

第一步：准备素材

这一步在 **① 准备素材** 页面完成。程序会自动：从视频里提取声音 → 清理 → 切成一句一句 → 识别成文字 → 过滤掉质量差的和不是你本人的片段 → 分析你的说话风格 → 挑选参考音频。你只需要填两个地方、点一个按钮。

6.1 填写声音名称

1 点页面最上面的 **声音名称**（新建请直接输入名字）输入框。

2 输入一个名字，例如 **我的声音**，按 **Enter**。

- 名字可以用中文，但不能包含 `\ / : * ? " < > |` 这些符号。
- 以后每次使用都要选同一个名字，这样才能用到你训练好的模型。
- 一台电脑可以有多个声音（例如"讲课声音""激情版"），它们的素材和模型互相独立。

6.2 选择素材

有两种方式，任选其一：

方式一（推荐）：填写文件夹路径

在 **或者填写电脑上的文件夹路径** 里输入

`D:\讲课素材`。

优点：不需要上传，视频再大、再多都很快。程序会自动找到文件夹及子文件夹里的所有视频和音频。

方式二：上传文件

点左边的 **上传视频/音频/字幕（可多选）** 区域，选择文件（按住 **Ctrl** 可多选），或者直接把文件拖进去。

适合文件较少、较小的情况。大视频上传会比较慢。



小技巧：打开 `D:\讲课素材` 文件夹 → 点地址栏 → **Ctrl + C** 复制路径 → 回到网页，点输入框 →

Ctrl + V 粘贴。


6.3 其它选项说明

一般保持默认即可。各选项的含义：

选项	默认值	说明与建议
语音识别引擎	faster-whisper	faster-whisper : 中文、英文都识别得好，推荐。 funasr : 阿里的中文识别模型，纯中文课程识别更准，但英文较弱（需要整合包里带有 funasr，一般都有）。 none : 不做识别，只用字幕文件里的文字（所有视频都有字幕时可选）。
素材语言	auto	auto : 每一句自动判断是中文还是英文（推荐）。素材全是中文可以选 zh，全是英文可以选 en。
降噪	auto	auto : 程序估算录音的噪音大小，只有噪音明显时才轻度降噪（推荐）。 on : 总是降噪。 off : 从不降噪。 降噪太狠会损伤音色，所以默认很保守。
视频有背景音乐	不勾选	勾选后会用 Demucs 去除背景音乐，需要额外安装 demucs 组件，处理也较慢。一般不勾，推荐用 4.6 节的方法。

6.4 开始处理并看懂日志

- 1 点橙色的 **开始准备素材** 按钮。
- 2 下方的 **运行日志** 会实时滚动显示进度。**第一次**运行时，程序会先下载语音识别模型（约 3GB），需要几分钟到十几分钟，请耐心等待。
- 3 全部完成后，日志下方会出现 "✅ **素材准备完成**" 的汇总信息。



6.5 看懂处理结果

汇总信息里每一项的意思：

项目	含义
保留 228 / 228 条，共 16.4 分钟	一共切出 228 个片段，全部保留（质量都合格），合计 16.4 分钟你说话的内容。
各语言分钟数 {'zh': 12.6, 'en': 3.8}	中文 12.6 分钟，英文 3.8 分钟。
验证集 12 条	程序留出 12 句 不参加训练 ，训练后用它们当"考题"挑选最像的模型、校准语速。
丢弃原因（如果有）	被自动删掉的片段数量和原因，见下表。
 黄色提示	素材可能不够的提醒，见下表。
你的语速	不含停顿时每秒说几个音节（字）。一般人讲课在 3.5~5.5 之间。
你的停顿习惯	你在逗号、句号、段落处平均停顿多少秒。生成时会模仿。
自动挑选的参考音频	最能代表你讲课状态的几句话，[zh/statement] 表示"中文 / 陈述句"，question 是疑问句，exclaim 是感叹句。

黄色提示的含义和处理：

提示	怎么办
可用素材只有 X 分钟。能训练，但建议 ≥ 30 分钟……	可以先继续往下做，看看效果；有条件的话再加素材（重新运行本步骤只会处理新文件）。
英文素材不足 5 分钟：英文会带一点「中文腔」……	只做中文课可以忽略；要做英文课请补充英文讲课录音。
素材里没有英文……	同上。

丢弃原因说明（被丢弃的片段不参与训练，可以在第 7 章的校对表里手动恢复）：

丢弃原因	意思
没有识别出文字	这一段可能是静音、音乐、咳嗽等。
疑似识别错误	识别结果像"谢谢观看""字幕由…"这类常见错误，或同一个词重复很多遍。
语言不是中文/英文	识别为其它语言。
太短 / 太长	短于 2 秒或长于 13 秒，不适合训练。
有爆音	录音音量过大导致失真。
识别置信度低 / 可能不是语音	识别模型自己也不确定，文字很可能不准。
语速异常（文字可能不对）	文字长度和音频时长明显对不上，多半是识别错了。

丢弃原因	意思
声音不像本人（可能是别人说话）	声纹和你的整体声纹差别很大，例如学生提问、插入的视频。
手动删除	你在校对表里把它标记为不保留。

6.6 需要多长时间

素材时长	大约用时（有 NVIDIA 显卡）
30 分钟	5~15 分钟（第一次另加下载识别模型的时间）
1 小时	10~30 分钟
3 小时	30~90 分钟



以后增加素材

把新的视频也放进 **D:\讲课素材**，再点一次 **开始准备素材**。程序只会处理新增的文件，之前处理过的和你校对过的内容都会保留。之后记得重新训练（第 8 章）。

第 7 章

校对文字（强烈建议）

7.1 为什么要校对

训练时，模型会把"这段声音"和"这段文字"一一对应起来学习。如果识别出的文字有错（例如把"推导式"识别成"推倒是"），模型就会学到错误的发音对应关系，生成时可能出现**读错字**、**吞字**、**语气奇怪**的情况。花 10~20 分钟校对，效果会明显更好，是性价比最高的一步。



如果你的素材都有准确的字幕文件（4.5 节），文字本身就是准确的，可以只快速浏览一遍。

7.2 在网页里校对

1 在 **① 准备素材** 页面往下拉，找到 **"校对文字"** 部分，点 **载入片段列表**。

2 表格里会列出所有片段，每行一个：

列	含义
id	片段编号 ("文件名_编号")，不要修改。
保留	✓ 参加训练；✗ 不参加。
语言	zh 中文 / en 英文（一般不用改）。
秒	片段时长。
文字	识别出的文字， 可以直接修改 。
丢弃原因	被自动丢弃的原因（保留的片段这一栏是空的）。

3 点击任意一行，下方的 **试听选中的片段** 会加载这一段录音，点 ▶ 播放，一边听一边核对文字。

4 发现错字：**双击**这一行的"文字"格子，修改成正确的文字，按 **Enter** 确认。

5 某一段不是你说的、质量很差、或者说错了话：把"保留"格子改成 ✗（也可以输入 0）。

6 想恢复被自动丢弃的片段：把它的"保留"改成 ✓（或 1）。

7 全部改完后，点橙色的 **保存修改**。下方会显示类似"已保存：{'text': 12, 'keep': 3, 'lang': 0}"，意思是改了 12 处文字、3 处保留状态。

校对文字（可选，但能明显提升效果）

识别错的字直接在表格里改；不想要的片段把「保留」改成 ✕。点击某一行可以试听。改完点「保存修改」。

id	保留	语言	秒	文字	丢弃原因
第1课_b6dd09_0000	✓	zh	3.9	大家好，欢迎来到今天的课程。	
第1课_b6dd09_0001	✓	zh	4.9	今天我们来学习Python里面的列表推导式。	
第1课_b6dd09_0002	✓	zh	5.2	它可以让代码变得更加简洁，也更容易阅读。	
第1课_b6dd09_0003	✓	zh	4	首先我们来看一个最简单的例子。	
第1课_b6dd09_0004	✓	zh	4.9	大家想一想，这段代码输出的结果是什么？	
第1课_b6dd09_0005	✓	zh	5.2	没错，它会生成一个从零到九的平方数列表。	
第1课_b6dd09_0006	✓	zh	4.5	接下来我们给它加上一个判断条件。	
第1课_b6dd09_0007	✓	zh	5.1	只保留其中的偶数，其它的数字全部过滤掉。	
第1课_b6dd09_0008	✓	zh	4.5	这种写法在实际项目里面用得非常多。	
第1课_b6dd09_0009	✓	zh	5.4	但是要注意，不要把太复杂的逻辑都塞进一行。	
第1课_b6dd09_0010	✓	zh	4.3	可读性永远比少写几行代码更重要。	
第1课_b6dd09_0011	✓	zh	3.3	好，我们再来看字典推导式。	
第1课_b6dd09_0012	✓	zh	6	它和列表推导式非常相似，只需要同时给出键和值。	

↓ New row → New column

载入片段列表 保存修改

试听选中的片段

图 7-1 校对表：点击一行即可在下方试听；双击“文字”格子可以修改



修改完一定要点 **保存修改**，否则关掉页面后修改会丢失。片段很多时，可以分几次校对，每次改完都保存。

校对时重点看什么

- **错别字和同音字**：专业术语最容易识别错，例如“推导式 / 推倒是”、“Python / 派森”。
- **漏字、多字**：录音里说了但文字里没有，或者相反。
- **标点**：句末有没有句号、问号。标点会影响模型学习停顿和语气，问句请用问号。
- **口头语**：录音里说了“嗯”“那个”，文字里也要写上（按实际说的写），或者把这一段删掉。
- **中英文**：英文单词按原样写英文，不要写成中文谐音。

7.3 用 Excel 校对（适合片段很多时）

- 1 打开 D:\VoiceTwin\workspace\我的声音\transcripts.csv（用 Excel 或 WPS 表格打开，中文不会乱码）。

- 2 修改 `text` 列的文字；不想要的行把 `keep` 改成 `0`。最后一列 `audio` 是音频文件的位置，可以复制路径去播放。
- 3 保存时选择**保持 CSV 格式**（Excel 提示"可能会丢失某些功能"时选"是 / 保持当前格式"）。
- 4 在 `D:\VoiceTwin` 打开命令提示符（3.7 节），输入 `voicetwin.bat review -v 我的声音` 按 `Enter`，程序会读回你的修改。



用 Excel 修改期间不要同时在网页里点"保存修改"，以免互相覆盖。二选一即可。

7.4 什么样的片段应该删掉

- 不是你本人的声音（程序没识别出来的漏网之鱼）。
- 咳嗽、笑场、清嗓子、明显口误后重说的片段。
- 有明显杂音（敲门、手机铃声、翻书声很大）的片段。
- 声音状态明显不对（很累、很哑）的片段。
- 文字实在听不清、无法确定的片段。

删掉少量片段不会影响效果，**宁缺毋滥**。

7.5 校对之后

点 **保存修改** 后，程序会自动重新统计语速、重新过滤、重新挑选参考音频，并更新你的说话风格档案。然后就可以进入第 8 章开始训练了。如果你是在训练**之后**才校对的，校对完需要**重新训练**一次，修改才会生效。

第 8 章

第二步：训练你的声音模型

这一步在 [② 训练模型](#) 页面完成。训练是让模型反复"听"你的素材、学会你的声音的过程，全部自动进行。训练结束后，程序还会**自动挑选最像你的模型版本**，并**校准语速**。

8.1 训练前的准备

- ☐ 已经完成第 6 章（准备素材），最好也完成了第 7 章（校对）。
- ☐ **关闭电脑自动睡眠**：打开"设置" → "系统" → "电源和电池"（或"电源"）→ "屏幕和睡眠"，把"接通电源时，使设备进入睡眠状态"改为 "**从不**"。笔记本请插上电源。
- ☐ 关闭大型游戏、视频剪辑、其它 AI 软件等占用显卡的程序。
- ☐ 预留 30~90 分钟（素材越多越久），期间电脑可以做轻度的事情（看网页、写文档），但会比较卡。

8.2 开始训练

- 1 确认页面最上面的 声音名称 是"我的声音"。
- 2 点 [② 训练模型](#) 标签页。
- 3 引擎 保持 **gptsovits**；SoVITS 轮数、GPT 轮数、Qwen3 轮数、batch 都保持 **0**（0 表示自动设置）。
- 4 点橙色的 **开始训练**。
- 5 下方的 训练日志 会显示进度。**训练期间不要关闭黑色窗口，也不要关闭或刷新网页。**
- 6 看到 "**✅ 训练完成，最佳模型：……**" 就表示全部完成。

GPT-SoVITS（推荐）：用你的素材微调，最像你；需要 NVIDIA 显卡（6GB+），1 小时素材约 30~60 分钟。

Qwen3-TTS：也可微调（显存需求更大）。IndexTTS 不需要训练，可以直接去第③步。

训练结束后会自动用验证集挑选最像你的模型，并校准语速。

引擎

gptsovits

SoVITS 轮数（0=自动）

0

GPT 轮数（0=自动）

0

Qwen3 轮数（0=默认）

0

batch（0=自动）

0

开始训练

重新挑选最佳模型

训练日志

21:44:14 | gsv_s1_train 进度 47%

21:44:14 | gsv_s1_train 进度 53%

21:44:14 | gsv_s1_train 进度 60%

21:44:14 | gsv_s1_train 进度 67%

21:44:14 | gsv_s1_train 进度 73%

21:44:14 | gsv_s1_train 进度 80%

21:44:14 | gsv_s1_train 进度 87%

21:44:14 | gsv_s1_train 进度 93%

21:44:14 | gsv_s1_train 进度 100%

21:44:15 | GPT-SoVITS 训练完成

21:44:15 | 启动 GPT-SoVITS 推理服务（端口 19990，模型 s8-g15）

21:44:17 | GPT-SoVITS 推理服务已就绪

21:44:17 | 识别校验不可用（未安装 faster-whisper：请执行 pip install "voicetwin[asr]"），将只用声纹和节奏打分

21:44:17 | 评估模型 s4-g5

21:44:19 | s4-g5：相似度 0.916 / 与原句 0.891 / 节奏偏差 0.066 → 综合 1.754

21:44:19 | 评估模型 s4-g10

21:44:21 | s4-g10：相似度 0.916 / 与原句 0.892 / 节奏偏差 0.047 → 综合 1.770

21:44:21 | 评估模型 s4-g15

21:44:21 | s4-g15：相似度 0.918 / 与原句 0.891 / 节奏偏差 0.045 → 综合 1.774

21:44:21 | 评估模型 s8-g5

21:44:22 | s8-g5：相似度 0.916 / 与原句 0.891 / 节奏偏差 0.066 → 综合 1.754

21:44:22 | 评估模型 s8-g10

21:44:22 | s8-g10：相似度 0.916 / 与原句 0.892 / 节奏偏差 0.047 → 综合 1.770

21:44:22 | 评估模型 s8-g15

21:44:23 | s8-g15：相似度 0.918 / 与原句 0.891 / 节奏偏差 0.045 → 综合 1.774

21:44:23 | 最佳模型：s4-g15；语速校准：{'zh': 1.0, 'en': 1.054}

✔ 训练完成，最佳模型：s4-g15，语速校准：{'zh': 1.0, 'en': 1.054}

图 8-1 训练完成：日志最后是自动挑选最佳模型的过程，底部显示最佳模型和语速校准结果

8.3 看懂训练日志

训练日志会依次经过下面这些阶段：

日志内容	这一阶段在做什么
训练素材：N 条，X 分钟；实验名 vt_.....	整理出参加训练的片段（验证集除外）。"实验名"是模型文件的名字前缀。
训练参数：batch=6，SoVITS 8 轮，GPT 15 轮（显存 12.0 GB）	程序根据你的显存和素材多少自动决定的训练参数。
1A 文本处理（音素 + BERT 特征）	把文字转换成发音信息。
1B 提取 HuBERT 特征与说话人声纹	提取每段录音的声音特征和你的声纹。
1C 提取语义 token	把声音转换成模型能学习的"语义单位"。
训练音色模型 SoVITS（共 8 轮）..... gsv_s2_train 进度 25%	学习你的音色。每完成一轮，进度增加一点；每一轮可能需要几分钟。

第 36 页 / 共 78 页

日志内容	这一阶段在做什么
训练语气与节奏模型 GPT（共 15 轮） gsv_sl_train 进度 20%	学习你的 语气和节奏 。
启动 GPT-SoVITS 推理服务.....已就绪	准备用训练好的模型试着说话。
评估模型 s4-g5 s4-g5: 相似度 0.925 / 与原句 0.901 / 节奏偏差 0.076 → 综合 1.765	逐个"考试": 让每个模型版本读验证集的句子, 和你的原声比较。s4-g5 表示"音色模型第 4 轮 + 语气模型第 5 轮"的组合。
最佳模型: s8-g15; 语速校准: {'zh': 1.04, 'en': 1.0}	综合分最高的组合被选为默认模型; 语速校准 1.04 表示模型读得稍慢, 生成时自动加快 4%。



如果看到"识别校验不可用"

日志里可能出现"识别校验不可用 (……)", 将只用声纹和节奏打分"。这表示用来检查错字的识别模型没有加载成功 (例如网络问题), 挑选模型时会少一项"错字率"评分, **不影响训练结果**, 可以忽略。正常情况下你会看到每个模型的"错字率 x%"。

8.4 训练需要多长时间

显卡	30 分钟素材	1 小时素材	3 小时素材
RTX 3060 / 4060	约 20~40 分钟	约 40~90 分钟	约 2~4 小时
RTX 3080 / 4070	约 15~25 分钟	约 25~50 分钟	约 1.5~2.5 小时
RTX 4090 / 5090	约 8~15 分钟	约 15~30 分钟	约 45~90 分钟

以上是粗略估计, 实际时间受显卡、CPU、硬盘速度和素材情况影响。

8.5 "自动挑选最佳模型"和"语速校准"是什么

训练过程中, 程序会在不同阶段保存多个模型版本 (例如音色模型第 4、8 轮, 语气模型第 5、10、15 轮)。训练得太少不够像, 训练得太多又可能"学过头" (变得不自然)。哪个版本最像你? 程序不靠猜, 而是用第 6 章留出的"验证集"——你的真实录音、没有参加训练——来考试:

- **相似度**: 生成的声音和你整体的声纹有多像;
- **与原句**: 和这一句你本人读的录音有多像;
- **错字率** (如可用): 把生成的声音再识别成文字, 和原文比对;
- **节奏偏差**: 同一句话, 模型读的时长和你本人读的时长差多少。

综合分最高的版本成为默认模型；同时根据"时长比"算出语速校准系数，让生成的语速和你本人一致。这一切都是自动的，你不需要做任何设置。

8.6 什么时候需要重新训练

情况	怎么做
增加了新的讲课素材	① 准备素材 → 开始准备素材（只处理新文件）→ ② 开始训练
在训练之后才校对了文字	保存校对后 → ② 开始训练
删掉了一些不好的片段	保存校对后 → ② 开始训练
只想重新挑选最佳模型（例如装好了识别模型后想加上错字率评分）	② 点 重新挑选最佳模型 （很快，不需要重新训练）



重新训练会覆盖同名的旧模型文件，这是正常的；新的模型会自动成为默认模型。

8.7 高级：手动设置训练参数

一般不需要改。如果你想自己控制：

参数	自动值	说明
SoVITS 轮数	素材 <30 分钟：8 ≥30 分钟：12	音色训练的轮数，最大 25。太多可能不自然。
GPT 轮数	15	语气节奏训练的轮数。素材很多时可以试试 20。
batch	显存 GB ÷ 2	每次一起训练多少条。显存不足（报 out of memory）时改小，例如 2。

第 9 章

第三步：生成讲课音频

这一步在 ③ **生成讲课音频** 页面完成，也是你以后**每天都会用**的功能：粘贴讲稿，点"生成"，得到用你的声音读出来的讲课音频和字幕。

9.1 准备讲稿

讲稿就是你要"说"的内容。可以直接在网页里粘贴文字，也可以上传文件（txt、md、srt、docx）。写法很简单：

- 像平时写讲稿一样写，**标点符号要写对**（句号、逗号、问号会影响停顿和语气）。
- **空一行表示分段**，段与段之间会有稍长的停顿（按你本人的习惯）。
- 想在某处停顿几秒，写 `[停顿=2]`（2 秒）。
- 标题可以用 `# 第四课：生成器表达式` 这样的写法，会被读出来并在后面停顿。

更多写法（Markdown、读音纠正、按字幕时间轴生成等）见第 10 章。

9.2 各项设置说明

粘贴讲稿或上传讲稿文件（txt / md / srt / docx）。空一行 = 段落停顿；`[停顿=1.5]` 指定停顿秒数。多音字、术语读音可在 `workspace/声音名/lexicon.txt` 里纠正。

讲稿

第四课：生成器表达式

大家好，欢迎回来。上节课我们学习了列表推导式，今天我们来学习生成器表达式。

生成器表达式的写法和列表推导式几乎一样，只是把中括号换成了小括号。那么它们有什么区别呢？`[停顿=1.5]`

最大的区别在于，生成器不会一次性把所有结果都放进内存。

Let's look at a quick example.

或上传讲稿文件

Drop File Here
- or -

引擎

gptsovits

质量 (best = 每句 5 个候选 + 识别校验, 最慢最好)

☐ fast ☒ balanced ☐ best

语速倍数 (1.0 = 和你本人一样)

1

指定参考音频 id (留空自动)

只重新生成第几句 (例如 3,5,8-10)

生成

图 9-1 ③ 生成讲课音频：左边是讲稿，右边是设置

设置	推荐值	说明
讲稿	—	粘贴讲稿文字。
或上传讲稿文件	—	上传 txt / md / srt / docx 文件。 上传了文件时，以文件为准 ，上面文本框的内容会被忽略。
引擎	gptsovits	用你训练好的 GPT-SoVITS 模型。（qwen3tts、indextts 是可选引擎，见 13.4 节；dummy 是测试用的，不要选。）
质量	balanced / best	见下表。
语速倍数	1.0	1.0 表示和你本人一样快（程序已自动校准）。想整体快一点调到 1.05，慢一点调到 0.95。
指定参考音频 id	留空	留空时程序自动选择（疑问句用疑问参考、陈述句用陈述参考）。想固定某种语气，可以填一个参考音频的 id（13.2 节）。
只重新生成第几句	留空	第一次生成留空。对某几句不满意时填编号（9.5 节）。

质量档位	每句生成几个版本	速度	适合
fast	1 个	最快	先快速试听讲稿内容
balanced	3 个，自动挑最像的	中等	日常使用（默认）
best	5 个，还会用识别模型检查漏字、读错，不合格自动重试	最慢	正式发布的课程

 第一次使用 best 档时，程序会下载一个用于检查错字的小型识别模型（约 500MB）。

9.3 开始生成

- 1

确认最上面的 声音名称 是"我的声音"。
- 2

粘贴讲稿，选择质量档位。
- 3

点橙色的 生成。
- 4

第一次生成时，程序需要先启动推理服务并加载模型，会多等 1 分钟左右；之后就快了。下方日志会逐句显示进度，例如 [3/7] 生成 上节课我们学习了.....（相似度 0.97）。
- 5

完成后，页面上会出现：
 - 结果：音频播放器，点 ▶ 直接试听；
 - 下载（音频 / 字幕 / 报告）：三个文件，点文件名后面的大小（如 "2.0 MB ↓"）即可下载；
 - 一个表格，列出每一句的声纹相似度和提示。



图 9-2 生成完成: 上方是试听播放器和下载文件, 下方表格是每一句的相似度

9.4 看懂结果表和报告

列	含义
#	句子编号 (重新生成某一句时用这个编号)。
句子	这一句的文字 (长句子会被自动拆成几段, 每段一个编号)。
声纹相似度	这一句和你的声纹有多像: ≥0.86 非常像 ; 0.78~0.86 比较像; 0.70~0.78 有点像; <0.70 不太像。
提示	程序发现的可能问题, 例如"语速过快/可能漏读""句中有 1.5s 的异常停顿""识别错字率 35%"。有提示的句子建议试听一下, 不满意就重新生成。

下载的 `.report.json` 报告文件里有更详细的信息 (每句的开始/结束时间、使用的参考音频、随机种子等), 一般不需要看。

9.5 只重新生成不满意的句子

听完后如果某几句不满意（语气不对、有杂音、读错字），**不需要全部重新生成**：

- 1 记下这几句的编号（结果表的 # 列），例如第 3 句和第 5 句。
- 2 在 `只重新生成第几句` 里填 `3,5`。可以写范围，例如 `8-10` 表示第 8、9、10 句；可以混合，例如 `3,5,8-10`。
- 3 讲稿和其它设置**保持不变**，再点一次 **生成**。
- 4 只有这几句会重新生成（换一组随机版本），其它句子直接用上一次的结果，所以很快。



程序会记住每一句

每一句生成的结果都会被缓存。如果你只修改了讲稿里的某一句话，再点生成时，**只有改动的那一句会重新生成**，其它句子秒出。所以放心地一边听一边改讲稿。



一句反复都不满意？

试试：① 把这句话改写得更加口语化或拆成两句；② 检查标点（问句用问号）；③ 用 `best` 档；④ 指定一个语气更合适的参考音频（13.2 节）。

9.6 生成的文件在哪里

除了在网页上下载，所有生成的文件也自动保存在：`D:\VoiceTwin\workspace\我的声音\outputs\`

文件	说明
<code>第四课_生成器表达式_20260930_213825.wav</code>	生成的音频。文件名 = 讲稿第一行（或讲稿文件名）+ 生成时间。
<code>....._213825.srt</code>	字幕文件，时间轴和音频对应。
<code>....._213825.report.json</code>	生成报告。

音频的音量已经自动调整到你原来的录音一致，可以直接剪进课程视频里。想输出 mp3 格式，见 13.3 节的 `output_format` 设置。

9.7 生成一整门课程的建议流程

- 1 **按节准备讲稿**：每节课一个 txt 或 md 文件，例如 `第01课.md`、`第02课.md`。

- 2 先用 **fast 档快速过一遍**：检查讲稿里有没有读错的词（多音字、专业术语、英文缩写），把需要纠正的写进读音词典（10.4 节）。
- 3 用 **best 档正式生成**：上传讲稿文件，生成。
- 4 **逐句试听**：重点听结果表里有"提示"或相似度较低的句子，不满意的用"只重新生成第几句"重做。
- 5 **导入剪辑软件**：音频 + 字幕一起导入，和画面对齐（第 11 章）。

第 10 章

讲稿的写法与读音控制

同一个模型，讲稿写得好不好，生成出来的效果差别很大。这一章告诉你：程序是怎么"读"你的讲稿的、怎样控制停顿、怎样纠正读错的字，以及怎样写出"听起来像你在讲"的讲稿。

10.1 支持的讲稿格式

格式	怎么得到	说明
.txt 纯文本	记事本、WPS 另存为"纯文本"	最推荐，最不容易出问题。UTF-8、GBK（记事本默认的"ANSI"）编码都能自动识别。
.md Markdown	Typora、Obsidian、VS Code 等	标题、列表、加粗、链接等格式会被自动清理，只读文字（10.5 节）。
.docx Word 文档	Word、WPS 文字	按段落读取。表格、图片、批注、页眉页脚不会被读出来。老版 .doc 格式不支持，请另存为 .docx 或 .txt。
.srt / .vtt 字幕	剪映等软件导出	按字幕的时间轴生成，每一句放在字幕对应的时间点上（10.7 节）。
直接粘贴	网页里的 讲稿 文本框	适合短内容。粘贴后的效果和 .txt 一样。

 长讲稿推荐用 .txt 或 .md 文件上传：方便保存、修改后再次上传，程序只会重新生成改动过的句子（9.5 节）。

10.2 程序是怎么把讲稿切成句子的

模型一次只能读一小段话，所以程序会先把讲稿切成一句一句，逐句生成，再按你本人的停顿习惯拼接起来。切分规则如下，了解它能帮你写出更顺的讲稿：

规则	具体做法
按句末标点切句	遇到 。 ! ? ; ... 和英文的 . ! ? ; 切开。英文里的小数（3.14）、缩写（Mr. / e.g. / etc.）不会被误切。
换行 = 句子结束	一行结束、而行尾没有标点时，会被当作一句话结束（自动补上句号）。行尾是逗号、顿号等标点时，下一行接着读，不会断句；英文句子在单词中间被硬换行（下一行以小写字母开头）时也会自动接回去。

规则	具体做法
空一行 = 分段	段与段之间用你本人的 段落停顿 （通常 1 秒左右），段内句子之间用 句子停顿 。
太短的句子会合并	少于 6 个字（音节）的句子，例如"好。""对吧？"，会和下一句合在一起生成，避免孤零零的一两个字听起来生硬。
太长的句子会拆开	中文超过 50 个字、英文超过约 45 个音节的句子，会在逗号、顿号等处拆成几段生成，中间用很短的 逗号停顿 连接，听起来仍然是一句话。
句子的语气类型	以问号结尾的是 疑问句 ，以感叹号结尾的是 感叹句 ，其它是 陈述句 。程序会给不同类型的句子挑不同语气的参考音频（13.2 节）。



为什么停顿会像我？

第 6 章准备素材时，程序已经从你的录音里统计出了你的停顿习惯（逗号处停多久、句号处停多久、换段落停多久），生成时就按这个习惯插入停顿，并且每次有轻微的自然波动，不会像机器一样整齐划一。

10.3 停顿标记：想在哪儿停，停多久

除了标点和空行，你还可以在讲稿里直接写**停顿标记**，精确控制停顿。标记本身不会被读出来，也不会出现在字幕里。

写法	效果	例子
[停顿] 或 [暂停]	段落停顿（按你的习惯，约 1 秒）	我们先看第一个例子。[停顿]
[pause] 或 [break]	同上（英文写法）	Let's move on. [pause]
[停顿=2]	停 2 秒	大家先想一想。[停顿=2]
[停顿=1.5]	停 1.5 秒	可以写小数
[停顿 3秒] 或 [停顿: 3]	停 3 秒	等号、冒号、空格都可以
[停顿=800毫秒]	停 0.8 秒	用毫秒更精确
[pause=800ms] / [pause=2s]	停 0.8 秒 / 2 秒	英文单位 ms、s
<break time="800ms"/>	停 0.8 秒	兼容其它配音软件的 SSML 写法

- 停顿标记要写在**句子后面**：它会替换掉这句话后面原本的停顿。
- 方括号用中文输入法的 **[]** 不行，必须是英文的 **[]**；里面的"停顿"两个字不能写错。
- 写在讲稿最开头的停顿标记会被忽略（音频开头本来就有一小段静音）。



录屏课程的好帮手

讲到"大家看屏幕上这段代码"时，后面加一个 `【停顿=3】`，就能留出 3 秒让画面演示，剪辑时对齐轻松很多（第 11 章）。

10.4 读音纠正词典：解决读错字、多音字、专业术语

模型偶尔会读错多音字（"行长"读成 xíng zhǎng）、专业术语或英文缩写（"SQL"该读 sequel 还是 S-Q-L）。遇到这种情况，把正确读法写进**读音纠正词典**，以后所有讲稿都会自动按你的读法来读，**字幕里仍然显示原文**。

- 1 打开文件夹 `D:\VoiceTwin\workspace\我的声音`，找到 `lexicon.txt`（第一次准备素材后自动创建）。
- 2 在文件上点右键 → `打开方式` → `记事本`。
- 3 文件开头有几行以 `#` 开头的说明和例子（`#` 开头的行不会生效）。在文件末尾，每行写一条：
`原文 => 实际朗读的文字`。
- ```
读音纠正词典：每行一条，格式为 原文 => 实际朗读的文字
SQL => sequel
GPT => G P T
Python3 => Python 三
行长 => 航长
重庆 => 虫庆
≥ => 大于等于
e.g. => for example
API => A P I
```
- 4 按 `Ctrl + S` 保存。如果记事本询问编码，选 **UTF-8**。
- 5 回到网页重新点 **生成**。包含这些词的句子会用新读法重新生成，其它句子直接用缓存，很快。

| 想解决的问题         | 词典写法                              | 说明                                                      |
|----------------|-----------------------------------|---------------------------------------------------------|
| 多音字读错          | <code>行长 =&gt; 航长</code>          | 用 <b>同音、不会读错的字</b> 代替。要写成词（两个字以上），不要只写一个字，否则会把所有"行"都换掉。 |
| 英文缩写要一个字母一个字母读 | <code>GPT =&gt; G P T</code>      | 字母之间加空格。                                                |
| 英文缩写要读成单词      | <code>SQL =&gt; sequel</code>     | 写成你平时的读法。                                               |
| 符号、公式          | <code>≥ =&gt; 大于等于</code>         | 模型不认识的符号可能被跳过，写成文字最稳。                                   |
| 你习惯的特殊叫法       | <code>for 循环 =&gt; four 循环</code> | 按你讲课时实际怎么说来写。                                           |

| 想解决的问题 | 词典写法         | 说明          |
|--------|--------------|-------------|
| 版本号、型号 | v2.0 => 二零版本 | 避免被读成奇怪的数字。 |



词典的匹配规则

① 长的词条优先：同时有 Python 和 Python3 时，先替换 Python3。② 纯英文 / 数字的词条按**整个单词**匹配：API => A P I 不会把 RAPID 里的 API 换掉。③ 中文词条是直接查找替换，所以要写得足够长、足够具体。④ 词典对**这个声音的所有讲稿**都生效。



词典只改变"送去读的文字"，不能改变模型的发音方式。如果某个词用各种写法都读不对，试试换一种说法（改讲稿），或者在它前后加逗号，让它单独成为一个短语。

## 10.5 用 Markdown 写讲稿

如果你习惯用 Markdown 写课件，可以直接上传 .md 文件。程序会按下面的规则处理：

| Markdown 写法            | 程序怎么处理                                                                     |
|------------------------|----------------------------------------------------------------------------|
| # 第四课：生成器表达式<br>(各级标题) | 读出来，自动补句号，前后各有一次段落停顿。                                                      |
| - 第一点、1. 第一点 (列表)      | 去掉前面的符号和编号，每一项作为一句读。想读出"第一、第二"，请把它们写进文字里。                                  |
| **重点**、*斜体*、`代码`       | 去掉符号，只读文字。                                                                 |
| [链接文字](网址)             | 只读"链接文字"，网址不读。                                                             |
| ![图片](xxx.png)         | 整个删掉，不读。                                                                   |
| > 引用                   | 去掉>，读引用的文字。                                                                |
| 表格                     | 每一行的各个格子用逗号连起来读（表格分隔线不读）。一般建议把表格改写成口语。                                     |
| ``` 代码块 ```            | <b>默认整块不读</b> （程序代码念出来没有意义）。想读代码块，把设置里的 skip_code_blocks 改成 false（13.3 节）。 |
| --- 分隔线                | 当作分段。                                                                      |
| 表情符号 😊                 | 删除，不读。                                                                     |
| 其它 HTML 标签             | 删除标签，保留文字（<break> 停顿标记除外）。                                                 |

## 10.6 数字、符号和中英混读

- **数字范围**：3~5 会读成"3 到 5"（英文句子里读成 "3 to 5"）。
- **破折号**：— 会变成一个逗号停顿。
- **各种括号**（[]《》[]{}<>）：括号符号本身不读，里面的文字照常读。书名号里的内容照常读。
- **普通数字、日期、百分比**：一般能正确读出。但电话号码、编号、版本号、代码、数学公式等**建议写成你想读的样子**，例如把  $x^2$  写成"x 的平方"，把  $1/3$  写成"三分之一"。
- **中文里夹英文单词**：直接写即可，例如"我们用 Python 的 list 来存数据"。英文单词前后加不加空格都可以。
- **整句英文**：会自动识别为英文句子，用你的英文参考音频、英文语速来读。一段话里中英文句子可以交替出现。



拿不准的读法，先用 fast 档生成试听一遍（几秒钟一句），把读错的词记下来统一写进词典，再用 best 档正式生成。

## 10.7 按字幕时间轴生成（给现成的视频重新配音）

如果你有一个视频和它的字幕文件（.srt），想用你的新声音把它重新配一遍，并且让每句话还出现在原来的时间点，可以直接把 **.srt 文件作为讲稿上传**：

- 1 在剪映等软件里给视频生成字幕，检查、修改好字幕文字，导出为 **.srt** 文件。
- 2 在 **③ 生成讲课音频** 的 **或上传讲稿文件** 里上传这个 .srt 文件。
- 3 点 **生成**。每一条字幕会被读出来，并放在这条字幕的**开始时间**上。
- 4 生成的音频长度和原视频对得上，可以直接替换原视频的声音（11.3 节）。



### 如果提示"第 N 句比字幕时间轴晚了 X 秒"

说明上一条字幕的文字太多、而它的时间段太短，你的语速读不完，后面的句子只能顺延。解决方法：精简上一条字幕的文字，或者在剪辑软件里把那一段画面放慢一点；也可以把 **语速倍数** 稍微调快（如 1.05）。



按字幕生成时，句子之间的停顿由字幕时间决定，讲稿里的 **[停顿]** 标记和"空行分段"规则不适用。

## 10.8 写出"像你在讲"的讲稿：12 条技巧

1. **用说话的方式写，不用书面语。**"咱们来看一下这个例子"比"下面展示一个示例"更像讲课。
2. **多用短句。**一句话最好不超过 30 个字。长句子容易读得平、读得急。
3. **标点要准确。**问句一定用问号，模型会用提问的语气；感叹句用感叹号；该停的地方加逗号。
4. **保留你的口头习惯。**如果你平时爱说"那么""对吧""好，"，适当写进讲稿，会更像你。但不要每句都加。
5. **不要用省略号代替停顿。**想停顿请用逗号、句号或 `[停顿=1]`。
6. **避免大段括号注释。**括号里的话读出来很突兀，改成"也就是说……"之类的口语。
7. **数字、符号写成读法**（10.6 节）。
8. **一个意思一段。**用空行分段，段落停顿会让听众有"换气"的感觉。
9. **重要的话单独成句。**"注意，这一点非常重要。"单独一句，比埋在长句子里效果好。
10. **中英文切换不要太频繁。**一句话里夹一两个英文术语没问题；中英文整句交替时，最好一段内保持同一种语言。
11. **和你的训练素材风格一致。**模型最擅长模仿你讲课的样子；用它念诗、演戏、喊口号效果会差很多。
12. **先试听再定稿。**写完先用 fast 档听一遍，把拗口的句子改顺。

## 10.9 一份完整的示例讲稿

下面这份讲稿用到了本章的大部分写法，你可以复制到网页里试一试：

# 第四课：生成器表达式

同学们好，欢迎回来。上节课我们学习了列表推导式，今天我们来学习一个和它非常相似、但是更节省内存的写法，叫做生成器表达式。

先想一个问题：如果我们要处理一个有一千万行的文件，把它全部读进列表里，会发生什么？`[停顿=1.5]`

对，内存很可能就不够用了。生成器表达式就是为了解决这个问题。

我们看屏幕上的这段代码。`[停顿=3]`

它和列表推导式的写法几乎一样，只是把方括号换成了圆括号。注意，这一点非常重要！

Today, let's also look at the English term. It's called a generator expression.

好，今天的内容就到这里，大家辛苦了！



这份讲稿会被切成 12 句：标题 1 句；第一段 2 句（第一段第一行行尾是顿号，所以和第二行连成一句）；提问句用疑问语气，读完停 1.5 秒；"我们看屏幕上的这段代码。"后停 3 秒；"注意，这一点非常重要！"用感叹语气；两句英文用英文参考音频和英文语速；最后一句用感叹语气结尾。

## 第 11 章

# 把生成的音频用到课程视频里

生成的音频（.wav）和字幕（.srt）可以直接导入任何剪辑软件。这一章以最常用的**剪映（电脑版 / 专业版）**为例，介绍三种常见的用法；也介绍一个不用剪辑软件、一条命令替换视频声音的方法。

## 11.1 三种常见用法

### A. 录屏 + 新配音

先写讲稿、生成音频，再对着音频录屏或做 PPT 动画。**最推荐**：嗓子不用出力，画面跟着声音走。

### B. 给旧视频换声音

原视频声音质量差（嗓子哑、有杂音），用字幕时间轴重新生成（10.7 节），再替换原音轨（11.3 节）。

### C. 补录、修改某一段

视频里某句话讲错了，只生成这一句，剪进去替换掉。因为音色、音量都和你一致，听众很难察觉。

### D. 纯音频课程

音频课、播客式课程：直接把生成的音频（可输出 mp3，13.3 节）上传到课程平台。

## 11.2 在剪映里使用生成的音频和字幕

- 1 打开剪映，点 **开始创作**，新建一个项目。
- 2 点左上角的 **导入**，选择你的视频（或录屏、PPT 导出的视频），以及生成的音频文件（在 D:\VoiceTwin\workspace\我的声音\outputs 里）。
- 3 把视频拖到下面的时间线上。如果原视频有声音而你不需要，在视频轨道左边点 **关闭原声**（喇叭图标）。
- 4 把生成的音频拖到视频轨道**下方**的音频轨道上，对齐开头。
- 5 **导入字幕**：在顶部的 **文本** 栏里找到 **本地字幕**（有的版本叫“导入字幕”），导入同名的 **.srt** 文件，字幕会自动按时间出现。字幕和音频要从同一个位置开始。
- 6 播放检查。画面和声音对不上时，可以拖动、分割音频片段来调整；也可以在讲稿里加停顿标记重新生成（10.3 节）。
- 7 点右上角 **导出**，分辨率、帧率按平时习惯设置即可。



剪映的菜单名称会随版本更新而变化，找不到时可以在剪映里搜索"导入字幕"。其它剪辑软件（Premiere、达芬奇、必剪、Camtasia 等）的用法类似：导入音频放到音轨，导入 SRT 字幕。



### 分段生成更好剪

一节课很长时，可以按"小节"分成几份讲稿分别生成，每份对应一段画面，剪辑时更好对齐；改动某一小节也只需要重新生成这一份。

## 11.3 不用剪辑软件：一条命令替换视频的声音

如果你只想把一个视频的原声音换成生成的音频（例如 10.7 节按字幕重新配音的场景），可以用 `mux` 命令，几秒钟就完成，**画面不会重新压缩，画质不变**：

- 1 按 3.7 节的方法，在 `D:\VoiceTwin` 打开命令提示符。
- 2 输入下面的命令（换成你自己的文件路径），按 `Enter`：

```
voicetwin.bat mux --video "D:\讲课素材\第1课.mp4" --audio "D:\VoiceTwin\workspace\我的声音\outputs\第1课_20260930_213825.wav" -o "D:\成品\第1课_新配音.mp4"
```

- 3 看到 ☒ 已生成 `D:\成品\第1课_新配音.mp4` 就完成了。

| 参数                           | 含义                                                               |
|------------------------------|------------------------------------------------------------------|
| <code>--video</code>         | 原视频文件。                                                           |
| <code>--audio</code>         | 生成的音频文件。                                                         |
| <code>-o</code>              | 输出的新视频文件（所在文件夹要先建好）。                                             |
| <code>--keep-original</code> | （可选）加上它会 <b>保留原音轨并和新音频混在一起</b> ，适合原视频里有背景音乐、你只想叠加解说的情况。不加就是完全替换。 |



小窍门：在文件上按住 `Shift` 点右键，选 `复制文件地址`（Windows 11 直接右键 → `复制文件地址`），再在命令提示符里右键粘贴，就不用手打路径了。路径里有空格或中文时，前后要加英文双引号。

## 11.4 让声音和画面对齐的技巧

- 需要等画面时，在讲稿对应位置加 `[停顿=秒数]`，例如演示操作前加 `[停顿=3]`。
- 已有视频要配音时，用字幕时间轴生成（10.7 节），比手动对齐省事得多。

- **整体长度差一点**：用 **语速倍数** 微调（0.95~1.05 之间听起来仍然自然），不要超过 0.9~1.1。
- **某一句太长/太短**：改写这一句，只重新生成这一句（9.5 节）。

## 11.5 声音后期处理建议

---

- 生成的音频已经**自动调整到和你原始录音一样的音量**，一般不需要再调音量、压缩。
- **不要加重的混响、变声、美化效果**，会让声音变得不像你。
- 加背景音乐时，把音乐音量调低（比人声低 15~20 dB，剪映里一般把音乐音量调到 10%~20%），避免盖住讲解。
- 生成的音频和你的真人录音可以混在一个视频里使用。如果听起来"空间感"不同（例如真人录音有房间回声），可以给两者加同样的轻微降噪或同样的 EQ，让它们更统一。
- 导出视频时，音频选 AAC、192kbps 或更高即可。

## 第 12 章

## 检验效果：评估相似度与盲测

"像不像"不能只凭感觉。这一章教你两种方法：用程序的 ④ 评估相似度 功能给任意一段音频打分；以及组织一次简单的盲测，让别人来判断哪段是真人、哪段是生成的。

## 12.1 用"评估相似度"给音频打分

- 1 确认最上面的 声音名称 是"我的声音"。
- 2 点 ④ 评估相似度 标签页。
- 3 在 音频 框里点 上传 图标 (↑)，选择要评估的音频文件 (wav、mp3 等都可以)；也可以直接把文件拖进框里。
- 4 (可选) 在 对应文字 里填入这段音频说的内容。填了之后程序会把音频识别成文字，和你填的对比，计算错字率和语速。第一次使用会下载一个小型识别模型。
- 5 点 评估 ，几秒钟后下方显示结果。



图 12-1 ④ 评估相似度：上传一段 34 秒的生成音频，结论为"非常像"

## 12.2 看懂评估结果

| 项目       | 含义与参考标准                                                                                                               |
|----------|-----------------------------------------------------------------------------------------------------------------------|
| 结论       | 根据声纹相似度给出的一句话结论：非常像 / 比较像 / 有点像 / 不太像。                                                                                |
| 声纹相似度    | 这段音频和你本人声纹的接近程度，0~1 之间，越大越像。 <b>≥0.86 非常像；0.78~0.86 比较像；0.70~0.78 有点像；&lt;0.70 不太像。</b> 作为参考：你本人的不同真实录音之间一般在 0.85 以上。 |
| 时长（秒）    | 去掉开头结尾静音后的长度。                                                                                                         |
| 语速（音节/秒） | （填了文字才有）每秒说多少个字/音节。                                                                                                   |
| 你本人的平均语速 | （填了文字才有）从你的素材里统计出的平均语速。两者越接近，节奏越像你。中文讲课一般在每秒 3.5~5 个字之间。                                                              |
| 音高偏差     | 这段音频的平均音高和你本人差多少个"半音"。 <b>1 个半音以内</b> 基本听不出差别；超过 2 个半音会感觉音调偏高或偏低。                                                     |
| 错字率      | （填了文字才有）识别出的文字和你填的文字有多少不同。5% 以下很好；超过 15% 说明可能有漏读、读错，或者识别模型听错了（专业术语、人名容易被识别错，不一定是真的读错了）。                               |
| 识别出的文字   | （填了文字才有）识别模型听到的内容，可以和原文逐字对照，找出读错的地方。                                                                                  |
| 提示       | 发现的问题，例如"语速过快/可能漏读""几乎没有声音"。显示"无"表示没发现问题。                                                                             |
| 声纹模型     | 用来计算相似度的模型名称（一般是 resemblyzer）。不同声纹模型的分数标准不同，不要跨模型比较。                                                                  |



### 分数是参考，耳朵是最终标准

声纹相似度衡量的是"音色"，对语气、节奏、口音不太敏感；0.9 分的音频也可能某一句语气不对。分数用来**快速比较**，最终请一定用耳朵听，或者做盲测（12.4 节）。

## 12.3 用评估功能做对比实验

评估功能最有用的地方是**比较**：同一段讲稿，用不同的方法生成，看哪种更像你。例如：

| 想比较什么              | 怎么做                                                   |
|--------------------|-------------------------------------------------------|
| 校对前 vs 校对后训练的模型    | 校对前训练一次、生成一段；校对后重新训练、生成同样的讲稿，分别评估。                    |
| balanced vs best 档 | 同一讲稿用两个档位各生成一次，分别评估。                                  |
| 不同的参考音频            | 在 <span>指定参考音频 id</span> 里填不同的 id 生成（13.2 节），比较分数和听感。 |
| 不同的引擎              | 用 gptsovits 和可选引擎（13.4 节）分别生成，比较分数。                   |

| 想比较什么              | 怎么做                                                      |
|--------------------|----------------------------------------------------------|
| 你自己的真实录音（作为"满分"参照） | 上传一段 <b>没有用来训练</b> 的真实录音（例如最近新录的一小段），看看你本人能得多少分，作为比较的基准。 |

## 12.4 盲测：让别人来判断

最客观的检验方法是**盲测**：让听的人不知道哪段是真人、哪段是生成的，看他们能不能分辨出来。

- 1 **准备真人录音**：找 5 段你本人的讲课录音，每段 10~20 秒。最好是**没有用来训练**的录音（例如新录的，或者特意没放进素材文件夹的一节课）。
- 2 **准备生成录音**：把这 5 段录音说的话整理成文字，用你的声音模型生成同样内容的 5 段音频（best 档）。
- 3 **统一格式**：把 10 段音频都转成同样的格式、同样的音量。可以在剪映里把它们放在一起统一导出，避免因文件格式、音量不同被"猜"出来。
- 4 **打乱顺序、重新命名**：把 10 个文件改名为 01.wav ~ 10.wav，顺序随机。自己另外记一张答案表（哪些是真人）。
- 5 **请人来听**：找 3~5 位熟悉你声音的人（同事、学生），每段听一遍，判断是"真人"还是"生成"。不要告诉他们各有几段。
- 6 **统计正确率**：用下面的表格记录，再按标准判断。

| 听众    | 01 | 02 | 03 | 04 | 05 | 06 | 07 | 08 | 09 | 10 | 判断正确数  |
|-------|----|----|----|----|----|----|----|----|----|----|--------|
| 答案    | 生成 | 真人 | 真人 | 生成 | 真人 | 生成 | 生成 | 真人 | 生成 | 真人 | —      |
| 张老师   | 真人 | 真人 | 生成 | 生成 | 真人 | 真人 | 生成 | 真人 | 真人 | 生成 | 5 / 10 |
| ..... |    |    |    |    |    |    |    |    |    |    |        |

| 平均正确率   | 说明                                                |
|---------|---------------------------------------------------|
| ≤ 60%   | 和瞎猜（50%）差不多， <b>基本听不出区别</b> 。效果非常好。               |
| 60%~80% | 有时能听出来。问问听众是怎么判断的（"这句语气怪""这里停顿太整齐"），针对性改进。        |
| > 80%   | 比较容易分辨。按 12.5 节和第 13 章的方法改进：增加素材、校对文字、使用 best 档等。 |

## 12.5 客观看待效果：哪些地方最容易露馅

根据经验，下面这些情况最容易让人听出是生成的，写讲稿和挑选句子时可以留意：

| 容易露馅的地方          | 改进方法                                                 |
|------------------|------------------------------------------------------|
| 很长的句子，后半句语调越来越平  | 拆成短句（10.8 节）。                                        |
| 强烈的情绪（大笑、激动、生气）  | 模型主要学会了你 <b>讲课时</b> 的状态，强烈情绪很难模仿。讲稿里尽量避免，或者这几句用真人录音。 |
| 笑声、咳嗽、清嗓子、“嗯……”等 | 无法生成，不要写在讲稿里。                                        |
| 专业术语、人名、多音字读错    | 用读音词典纠正（10.4 节）。                                     |
| 停顿太规律            | 程序已经加入了自然波动；也可以手动加一些 <code>【停顿=...】</code> 让节奏有变化。   |
| 英文带中文腔           | 增加你讲英文的素材（4.3 节）后重新训练。                               |
| 个别句子有杂音、电流声、吞字   | 只重新生成这几句（9.5 节）；用 best 档会自动检查和重试。                    |



任何声音克隆技术都做不到 100% 无法分辨。本程序的目标是：在正常讲课内容上，让大多数听众**注意不到**是生成的。关于公开使用时是否需要说明，请看附录 D。

第 13 章

# 进阶技巧：让声音更像你

按前面的步骤操作，已经能得到不错的效果。这一章介绍几种进一步提升效果的方法，以及设置文件、可选引擎、备份和换电脑等进阶操作。

## 13.1 提升相似度的方法（按效果从大到小）

| # | 方法         | 具体怎么做                                                               |
|---|------------|---------------------------------------------------------------------|
| 1 | 增加优质素材     | 从 30 分钟增加到 1~3 小时，效果提升最明显（4.2 节）。放入新素材后：<br>① 准备素材（只处理新文件）→ ② 重新训练。 |
| 2 | 校对文字       | 识别错的字会变成模型的"口误"。花 10~20 分钟校对（第 7 章），然后重新训练。                         |
| 3 | 剔除不好的素材    | 把嗓子哑之后、感冒时、非常疲惫时的录音从素材里拿掉；在校对表里把有杂音、有别人说话的片段设为不保留。                  |
| 4 | 用 best 档生成 | 每句生成 5 个版本挑最像的，并自动检查漏字、读错（9.2 节）。                                   |
| 5 | 挑一个满意的参考音频 | 参考音频决定了生成时的"状态"和"语气"。挑一条你最满意的，固定使用（13.2 节）。                         |
| 6 | 改写讲稿       | 口语化、短句、标点准确（10.8 节）。                                                |
| 7 | 补充英文素材     | 要做英文课时特别重要（4.3 节）。                                                  |

## 13.2 指定参考音频：固定你想要的语气

生成每一句话时，模型都需要一段你的真实录音作为**参考音频**，模仿它的音色、状态和语气。准备素材时，程序已经自动挑出了约 8~10 条最有代表性的参考音频（中文陈述句、疑问句、感叹句，英文句子各有），生成时会根据句子的语言和类型自动选择。

如果你觉得生成的语气整体偏平淡、偏急促，或者某一条参考音频的状态特别好，可以**手动指定**一条：

- 1 打开文件夹 `D:\VoiceTwin\workspace\我的声音\references`，里面是所有参考音频，例如：

```
references\
├─ 第1课_b6dd09_0021.wav ← 这里有一个常见的错误，很多同学都会犯。
├─ 第1课_b6dd09_0047.wav ← 但是要注意，不要把太复杂的逻辑都塞进一行。
├─ 第2课_b09a84_0063.wav ← 那么什么时候应该用普通的循环呢？（疑问句）
├─ 第3课_ac0ef9_0061.wav ← 今天的内容就到这里，大家辛苦了！（感叹句）
└─
```

- 2 双击逐个试听，找一条你最满意的（声音状态好、语气自然、没有杂音）。
- 3 它的文件名去掉 `.wav` 就是参考音频 id，例如 `第1课_b6dd09_0047`。在文件上点右键 → `重命名`，按 `Ctrl + C` 复制文件名（复制后按 `Esc` 取消重命名）。
- 4 在 **③ 生成讲课音频** 的 `指定参考音频 id` 里粘贴这个 id，然后生成。



#### 参考音频的文字在哪看？

用记事本打开 `D:\VoiceTwin\workspace\我的声音\references.json`，每一条参考音频都有 `id`（编号）、`text`（说的内容）、`lang`（zh 中文 / en 英文）、`kind`（statement 陈述 / question 疑问 / exclaim 感叹）、`duration`（秒数）。



指定参考音频后，**所有句子**（包括疑问句、英文句子）都会用这一条参考。所以：中文讲稿请指定中文参考，英文讲稿请指定英文参考；如果讲稿里疑问句很多、希望疑问语气更明显，就留空让程序自动选。



#### 想用一条自己新录的参考？

参考音频必须来自素材。可以专门录一段 3~10 秒、状态很好的话（例如“同学们好，今天我们来学习一个新的知识点。”），放进素材文件夹，重新 ① 准备素材；它有很大概率会被选为参考音频。

## 13.3 设置文件 config.yaml 详解

网页上没有的设置，都在 `D:\VoiceTwin\config.yaml` 里。大多数人不需要修改它。

### 如何修改

- 1 **先备份**：复制一份 `config.yaml`，改名为 `config备份.yaml`。
- 2 在 `config.yaml` 上点右键 → `打开方式` → `记事本`。
- 3 按 `Ctrl + F` 搜索要改的项目名称，例如 `output_format`，修改冒号后面的值。

4 按 `Ctrl + S` 保存，关闭黑色窗口，重新双击桌面图标启动，设置才会生效。

### ❗ 修改时的三条规则

- ① 冒号后面必须有一个空格：`output_format: mp3` ✓，`output_format:mp3` ✗。② 每行前面的空格缩进不能改（缩进表示层级），也不能用 Tab 键。③ `#` 后面是说明文字，不影响设置。

改坏了怎么办？把备份的文件改回 `config.yaml`；或者在命令提示符里运行 `voicetwin.bat init-config --force` 恢复默认设置（旧文件会自动备份为 `config.yaml.bak`；恢复默认后需要重新运行一次 `install_windows.bat` 写入整合包路径）。

## 常用设置一览

| 设置项                                                   | 默认值               | 说明                                                                                                            |
|-------------------------------------------------------|-------------------|---------------------------------------------------------------------------------------------------------------|
| <b>生成（synth 部分）</b>                                   |                   |                                                                                                               |
| <code>output_format</code>                            | wav               | 输出格式： <code>wav</code> （无损，推荐剪辑用）或 <code>mp3</code> （文件小，适合直接发布）。                                             |
| <code>quality</code>                                  | balanced          | 默认质量档位：fast / balanced / best。                                                                                |
| <code>speed</code>                                    | auto              | auto 表示使用自动校准的语速（和你本人一致）。                                                                                     |
| <code>pauses</code>                                   | profile           | <code>profile</code> ：按你本人的停顿习惯； <code>fixed</code> ：使用下面 <code>fixed_pauses</code> 里的固定秒数。                   |
| <code>fixed_pauses</code>                             | 0.25 / 0.55 / 1.1 | 固定停顿时，逗号（clause）、句子（sentence）、段落（paragraph）各停多少秒。                                                             |
| <code>loudness</code>                                 | profile           | <code>profile</code> ：音量和你的原始录音一致；也可以写数值如 <code>-16</code> （更响，适合手机外放）； <code>off</code> 不调整。                 |
| <code>subtitles</code>                                | true              | 是否同时输出 .srt 字幕。                                                                                               |
| <code>skip_code_blocks</code>                         | true              | Markdown 讲稿里的代码块是否跳过不读。                                                                                       |
| <code>cer_retry_threshold</code>                      | 0.15              | best 档：错字率超过 15% 自动重新生成这句。                                                                                    |
| <code>max_retries</code>                              | 2                 | best 档：每句最多重试几次。                                                                                              |
| <code>max_units_zh</code> / <code>max_units_en</code> | 50 / 45           | 一段最多多少个字 / 音节，超过会拆开（10.2 节）。                                                                                  |
| <b>素材准备（prepare 部分）</b>                               |                   |                                                                                                               |
| <code>asr: engine</code>                              | faster-whisper    | 识别引擎。 <b>纯中文素材</b> 可以改成 <code>funasr</code> ，中文识别更准，而且从国内的 ModelScope 下载，速度快。                                 |
| <code>asr: model</code>                               | large-v3          | 识别模型。显存小（6GB）可以改成 <code>large-v3-turbo</code> 或 <code>medium</code> ；用 funasr 时写 <code>paraformer-zh</code> 。 |
| <code>denoise</code>                                  | auto              | 降噪：auto 只在噪音明显时轻度降噪； <code>off</code> 关闭； <code>on</code> 总是降噪。                                               |

| 设置项                                                         | 默认值         | 说明                                                                               |
|-------------------------------------------------------------|-------------|----------------------------------------------------------------------------------|
| <code>min_duration</code> / <code>max_duration</code>       | 2.0 / 12.0  | 切出的片段最短 / 最长秒数。                                                                  |
| <code>speaker_outlier</code>                                | true        | 是否用声纹剔除不是你本人的片段。                                                                 |
| <code>validation_count</code>                               | 12          | 留多少条不参加训练、用来挑选最佳模型。                                                              |
| <code>references: count</code>                              | 8           | 挑选多少条参考音频。                                                                       |
| GPT-SoVITS 引擎（backends → gptsovits 部分）                      |             |                                                                                  |
| <code>root</code>                                           | （安装时写入）     | GPT-SoVITS 整合包的位置。移动整合包后要改这里（或重新运行安装程序）。                                         |
| <code>is_half</code>                                        | true        | 半精度加速。GTX 10 系列及更老的显卡请改成 <code>false</code> 。                                    |
| <code>port</code>                                           | 9880        | 推理服务的端口。如果 9880 被其它程序占用，改成 9881 等。                                               |
| <code>train: batch_size</code>                              | auto        | 训练批大小。显存不足时改成 <code>2</code> 或 <code>1</code> 。                                  |
| <code>train: sovits_epochs</code> / <code>gpt_epochs</code> | auto        | 训练轮数（8.7 节）。                                                                     |
| <code>infer: aux_refs</code>                                | 2           | 生成时额外融合几条参考音频的音色，让音色更稳定。一般不用改。                                                   |
| 其它                                                          |             |                                                                                  |
| <code>workspace</code>                                      | ./workspace | 数据存放位置。想把数据放到其它盘，可以改成例如 <code>E:/VoiceTwinData</code> （先把原来的 workspace 文件夹复制过去）。 |
| <code>backend</code>                                        | gptsovits   | 默认引擎。                                                                            |

### 13.4 可选引擎：Qwen3-TTS 与 IndexTTS

除了默认的 GPT-SoVITS，声音分身还支持两个开源引擎。它们主要做**零样本克隆**（不训练，只用参考音频模仿），适合对比试听或临时使用：

| 引擎             | 特点                         | 是否需要训练 | 显存要求              |
|----------------|----------------------------|--------|-------------------|
| GPT-SoVITS（默认） | 用你的素材微调， <b>最像你</b> ；安装最简单 | 需要     | 6GB 以上            |
| Qwen3-TTS      | 阿里开源，零样本自然度高，也支持微调         | 可选     | 零样本 8GB+；微调 12GB+ |
| IndexTTS 2.5   | B 站开源，零样本克隆，情绪和时长控制强       | 不需要    | 8GB+              |

 这两个引擎需要单独安装（要用到 conda、git 等工具），步骤比较专业，没有编程基础的用户建议只用默认的 GPT-SoVITS。安装方法见项目主页 README 的"可选引擎"一节。安装好后，在 ③ 生成讲课音频 的 **引擎** 里选择即可；环境检查里对应的行会从  变成 .

## 13.5 管理多个声音

一个"声音名称"就是一套独立的素材和模型。你可以建多个声音，互不影响，例如：

- "我的声音"：日常讲课（中英文素材放在一起，推荐）。
- "我的声音-精神饱满"：只放状态最好的几节课，用来做重要的公开课。
- 帮同事做一个（需要对方本人授权，见附录 D）。

新建方法：在最上面的 **声音名称** 里输入新名字，然后从 ① 准备素材 开始。切换方法：点 **声音名称** 右边的小三角选择。

 声音名称不能包含 \ / : \* ? " < > | 这些字符。每个声音训练出的模型都会占用几百 MB 硬盘空间。

## 13.6 备份、换电脑和释放硬盘空间

### 需要备份什么

| 文件夹                                                                           | 内容                                          |
|-------------------------------------------------------------------------------|---------------------------------------------|
| D:\VoiceTwin\workspace                                                        | 所有声音的素材片段、校对结果、读音词典、参考音频、生成的音频。 <b>最重要。</b> |
| D:\GPT-SoVITS\SoVITS_weights_v2ProPlus<br>D:\GPT-SoVITS\GPT_weights_v2ProPlus | 训练好的模型文件（文件名以 <b>vt_</b> 开头）。               |
| D:\VoiceTwin\config.yaml                                                      | 你的设置。                                       |

### 换电脑

- 1 把 D:\VoiceTwin 和 D:\GPT-SoVITS 两个文件夹整个复制到新电脑（用移动硬盘）。推荐放在和原来一样的位置（都在 D 盘根目录）；放到别的位置也可以，下一步安装时输入新的整合包路径即可，训练好的模型会被自动找到。
- 2 在新电脑上双击 D:\VoiceTwin\install\_windows.bat 重新安装一次（会重新生成桌面图标，已有的设置和数据会保留）。
- 3 双击桌面图标，选择"我的声音"，直接去 ③ 生成讲课音频 就能用了，不需要重新训练。

## 释放硬盘空间

- **句子缓存：**每一句生成的结果都会缓存（9.5 节），时间长了会占用较多空间。在命令提示符运行 `voicetwin.bat clear-cache -v 我的声音` 清空。清空后不影响模型，只是下次生成同样的句子时要重新生成。
- **旧的生成结果：**`workspace\我的声音\outputs` 里不需要的音频可以直接删除。
- **训练中间文件：**`D:\GPT-SoVITS\logs\vt_.....` 是训练时产生的中间文件，训练完成后可以删除（下次重新训练会自动重新生成，只是多花一点时间）。
- **多余的模型版本：**训练会保存多个版本的模型（文件名里有 e4、e8 或 e5、e10、e15 等）。**不建议手动删除**，删错了会导致生成失败；确实需要空间时，可以只保留 **② 训练模型** 页面显示的最佳模型对应的文件。

## 13.7 在局域网或手机上使用（注意隐私）

默认情况下网页界面只能在本机打开。如果想在同一个局域网里的另一台电脑或平板上使用，可以在命令提示符里运行：

```
voicetwin.bat webui --host 0.0.0.0 --port 7860
```

然后在另一台设备的浏览器里访问 `http://这台电脑的IP地址:7860`（IP 地址可以在命令提示符里输入 `ipconfig` 查看"IPv4 地址"）。Windows 防火墙可能会弹窗询问，选择"允许"（仅专用网络）。



### 不要随意使用 --share

`voicetwin.bat webui --share` 会生成一个**任何人都能访问**的公网链接，别人拿到链接就能用你的声音生成任意内容。除非你完全清楚风险，否则不要使用。

## 第 14 章

## 命令行用法（选读）

网页界面能完成所有日常操作。命令行适合想**批量处理**（例如一次生成十几节课）或者想自动化的用户。不熟悉电脑的老师可以跳过这一章。

## 14.1 基本用法

- 1 按 3.7 节的方法，在 `D:\VoiceTwin` 打开命令提示符。
- 2 所有命令的格式都是：`voicetwin.bat 命令 参数.....`，输入后按 `Enter`。
- 3 查看所有命令：`voicetwin.bat -h`；查看某个命令的详细参数：`voicetwin.bat narrate -h`。



## 路径的写法

文件路径建议写**完整路径**（例如 `D:\讲稿\第1课.md`），路径里有空格时前后加英文双引号。`-v` 后面是声音名称，和网页里的“声音名称”一致。

## 14.2 全部命令一览

| 命令                   | 作用                     | 例子                                                              |
|----------------------|------------------------|-----------------------------------------------------------------|
| <code>doctor</code>  | 环境检查                   | <code>voicetwin.bat doctor</code>                               |
| <code>list</code>    | 列出所有声音及素材、训练情况         | <code>voicetwin.bat list</code>                                 |
| <code>prepare</code> | 准备素材（= 网页 ①）           | <code>voicetwin.bat prepare -v 我的声音 -i D:\讲课素材</code>           |
| <code>review</code>  | 读回 Excel 校对表的修改（7.3 节） | <code>voicetwin.bat review -v 我的声音</code>                       |
| <code>analyze</code> | 重新分析说话风格（语速、停顿、音高、音量）  | <code>voicetwin.bat analyze -v 我的声音</code>                      |
| <code>train</code>   | 训练并自动挑选最佳模型（= 网页 ②）    | <code>voicetwin.bat train -v 我的声音</code>                        |
| <code>select</code>  | 只重新挑选最佳模型、校准语速         | <code>voicetwin.bat select -v 我的声音</code>                       |
| <code>narrate</code> | 把讲稿文件生成音频 + 字幕（= 网页 ③） | <code>voicetwin.bat narrate -v 我的声音 D:\讲稿\第1课.md -q best</code> |
| <code>say</code>     | 直接生成一句话（不输出字幕）         | <code>voicetwin.bat say -v 我的声音 "同学们好，欢迎来到今天的课程。"</code>        |

| 命令                           | 作用                        | 例子                                                                    |
|------------------------------|---------------------------|-----------------------------------------------------------------------|
| <code>evaluate</code>        | 评估一段音频有多像你 (= 网页④)        | <code>voicetwin.bat evaluate -v 我的声音 D:\测试.wav --text "音频里说的话"</code> |
| <code>auto</code>            | 全自动：准备 → 训练 → 挑选 → 生成一段试听 | <code>voicetwin.bat auto -v 我的声音 -i D:\讲课素材</code>                    |
| <code>mux</code>             | 把音频放进视频（替换原声）             | 见 11.3 节                                                              |
| <code>download-models</code> | 下载缺少的 GPT-SoVITS 预训练模型    | <code>voicetwin.bat download-models --source hf-mirror</code>         |
| <code>clear-cache</code>     | 清空句子缓存                    | <code>voicetwin.bat clear-cache -v 我的声音</code>                        |
| <code>init-config</code>     | 生成 / 更新设置文件               | <code>voicetwin.bat init-config --gptsovits-root D:\GPT-SoVITS</code> |
| <code>webui</code>           | 启动网页界面 (= 双击桌面图标)         | <code>voicetwin.bat webui --port 7861</code>                          |

## 14.3 常用参数

| 参数                                                                                             | 适用命令            | 含义                                     |
|------------------------------------------------------------------------------------------------|-----------------|----------------------------------------|
| <code>-v 名称</code>                                                                             | 大多数命令           | 声音名称（必填）。                              |
| <code>-i 路径 [路径...]</code>                                                                     | prepare、auto    | 素材文件或文件夹，可以写多个，用空格隔开。                  |
| <code>--asr funasr</code>                                                                      | prepare         | 换识别引擎（faster-whisper / funasr / none）。 |
| <code>--language zh</code>                                                                     | prepare         | 素材语言：auto（逐段判断） / zh / en。             |
| <code>--denoise off</code>                                                                     | prepare         | 降噪：auto / on / off。                    |
| <code>--segmentation srt</code>                                                                | prepare         | 切分方式：auto / srt（按字幕） / energy（按静音）。    |
| <code>--sovits-epochs 12</code><br><code>--gpt-epochs 20</code><br><code>--batch-size 2</code> | train           | 手动设置训练轮数和批大小（8.7 节）。                   |
| <code>--no-select</code>                                                                       | train           | 训练后不自动挑选模型。                            |
| <code>-q best</code>                                                                           | narrate、say     | 质量档位：fast / balanced / best。           |
| <code>-n 8</code>                                                                              | narrate、say     | 每句生成几个版本（覆盖质量档位的默认值）。                  |
| <code>--speed 1.05</code>                                                                      | narrate、say     | 语速倍数。                                  |
| <code>--ref 第1课_b6dd09_0047</code>                                                             | narrate、say     | 指定参考音频 id（13.2 节）。                     |
| <code>--redo 3,5,8-10</code>                                                                   | narrate         | 只重新生成指定的句子（9.5 节）。                     |
| <code>-o D:\成品\第1课.mp3</code>                                                                  | narrate、say、mux | 输出文件（写 .mp3 就输出 mp3）。                  |
| <code>--no-srt</code>                                                                          | narrate         | 不输出字幕。                                 |
| <code>-b gptsovits</code>                                                                      | train、narrate 等 | 指定引擎。                                  |

| 参数                     | 适用命令 | 含义                     |
|------------------------|------|------------------------|
| <code>--verbose</code> | 所有命令 | 显示详细日志和完整错误信息（排查问题时用）。 |

## 14.4 实例：一次生成一整门课

假设你把 12 节课的讲稿放在 `D:\讲稿` 里（`第01课.md` ~ `第12课.md`），想全部用 `best` 档生成，可以在 `D:\VoiceTwin` 里新建一个文本文件，改名为 `批量生成.bat`，用记事本写入：

```
@echo off
chcp 65001 >nul
cd /d "%~dp0"
for %%f in ("D:\讲稿*.md") do (
 echo 正在生成 %%~nf
 call voicetwin.bat narrate -v 我的声音 "%%f" -q best -o "D:\成品\%%~nf.wav"
)
echo 全部完成!
pause
```

保存时在记事本的"另存为"对话框里把编码选为 **UTF-8**。先建好 `D:\成品` 文件夹，然后双击 `批量生成.bat`，电脑会一节一节地生成，完成后每节课的音频和字幕都在 `D:\成品` 里。可以晚上开始，第二天早上来看结果。



每节课生成完会在窗口里列出有"提示"的句子（例如  第 7 句：语速过快/可能漏读（可用 `--redo 7` 重新生成）），按提示用 `--redo` 重做那几句即可。

## 14.5 用 Excel 校对后同步

7.3 节介绍了用 Excel 校对 `transcripts.csv`。改完保存后，除了在网页里点按钮，也可以在命令行运行：

```
voicetwin.bat review -v 我的声音
voicetwin.bat train -v 我的声音
```

## 第 15 章

## 常见问题与故障排除

遇到问题先别急。绝大多数问题都能在这一章找到答案。每个问题都按"现象 → 原因 → 解决办法"来写。找不到答案时，看 15.8 节如何收集信息求助。

## 15.1 安装阶段

**问** 双击 `install_windows.bat` 后，黑色窗口一闪就没了

原因：系统阻止了 PowerShell 脚本运行，或者安装包没有完整解压。

解决：① 确认你是在解压后的 `D:\VoiceTwin` 文件夹里双击，而不是在压缩包里直接双击；② 在 `install_windows.ps1` 上点右键 → 使用 PowerShell 运行；③ 如果仍然不行，按 `Win` 键，输入 `powershell`，打开"Windows PowerShell"，输入下面这行后回车：  
`powershell -ExecutionPolicy Bypass -File D:\VoiceTwin\install_windows.ps1`

**问** 提示"没有找到……\runtime\python.exe"

原因：输入的 GPT-SoVITS 整合包路径不对。

解决：打开你的整合包文件夹，确认里面直接能看到 `runtime` 文件夹和 `go-webui.bat`。如果解压后多套了一层文件夹（例如 `D:\GPT-SoVITS\GPT-SoVITS-v2pro-2026xxxx\runtime`），要输入里面那一层的路径。然后重新运行安装程序。

**问** 提示"这个 GPT-SoVITS 整合包版本太旧（缺少 `api_v2.py`）"

解决：按 3.2 节重新下载最新版整合包。

**问** 提示"安装失败：pip install……请检查网络后重新运行安装程序"

原因：下载组件时网络中断。安装程序会先用国内镜像，失败后再试官方源。

解决：检查网络（关掉可能干扰的代理 / 加速器，或者反过来打开它），重新双击 `install_windows.bat`。重复运行是安全的，已经装好的部分不会重复下载。

**问** 提示"安装路径里有中文或空格"

这是提醒不是错误。个别组件对中文路径支持不好，建议按手册把程序放在 `D:\VoiceTwin`，整合包放在 `D:\GPT-SoVITS`。

**问** 环境检查里 `ffmpeg` 显示 ❌

解决：重新运行安装程序。仍然不行的话，确认整合包目录里有 `ffmpeg.exe`（整合包一般自带）；也可以在命令提示符里运行 `D:\GPT-SoVITS\runtime\python.exe -m pip install imageio-ffmpeg` 后再检查。

**问 杀毒软件报毒 / 拦截**

安装过程会下载 Python 组件、生成 .bat 脚本，个别杀毒软件可能误报。请从本项目的 GitHub Release 页面下载（3.1 节），然后在杀毒软件里把 `D:\VoiceTwin` 和 `D:\GPT-SoVITS` 加入信任区。

## 15.2 启动与网页界面

---

**问 双击桌面图标后，浏览器没有自动打开**

解决：看黑色窗口里有没有出现 `Running on local URL: http://127.0.0.1:7860`。出现了就手动打开浏览器，输入 `127.0.0.1:7860` 回车。推荐使用 Edge 或 Chrome 浏览器。

**问 浏览器显示"无法访问此网站"**

原因：程序还没启动完成，或者黑色窗口被关掉了、出错了。

解决：确认黑色窗口还开着；等 30 秒后刷新页面。黑色窗口里有红色报错的话，按 15.8 节处理。

**问 黑色窗口提示端口被占用（Cannot find empty port / address already in use）**

原因：之前打开的声音分身没关，或者其它程序占用了 7860 端口。

解决：关掉所有声音分身的黑色窗口，再重新双击图标；或者重启电脑。也可以换一个端口启动：在命令提示符运行 `voicetwin.bat webui --port 7861`，然后访问 `127.0.0.1:7861`。

**问 黑色窗口里的中文显示成乱码**

一般不影响使用，网页界面里的文字是正常的。启动脚本已经设置了 UTF-8 编码；个别老版本 Windows 仍可能显示乱码，可以忽略。

**问 网页上点了按钮没反应 / 一直转圈**

准备素材、训练、第一次生成都需要较长时间，请看下方日志有没有在更新。日志完全不动超过 10 分钟，看黑色窗口有没有报错。刷新网页会丢失当前页面的显示，但**正在后台运行的任务会继续**，完成后结果照常保存在 workspace 里。

**问 下拉框里找不到"我的声音"**

点  **刷新**。仍然没有的话，说明素材准备还没成功完成过一次，或者 config.yaml 里的 `workspace` 被改过。

## 15.3 准备素材阶段

---

**问 提示"没有找到任何视频或音频文件"**

原因：路径写错，或者文件格式不在支持列表里（4.4 节）。

解决：在文件夹地址栏复制路径再粘贴；确认文件扩展名（在资源管理器"查看"里勾选"文件扩展名"）。

**问 下载识别模型很慢，或者失败**

程序默认使用国内镜像 (hf-mirror.com)。如果还是失败：① 换个时间再试；② 素材以中文为主的话，在 **识别引擎** 里改用 **funasr** (从阿里 ModelScope 下载，国内速度快)；③ 显存或网速有限时，可以在 config.yaml 里把识别模型改成 **large-v3-turbo** (更小更快)。

**问 保留下来的素材比预期少很多**

看处理结果里的"丢弃原因" (6.5 节)：

- "声音不像本人"很多：可能素材里确实有较多别人说话；也可能你的录音环境差别很大 (不同教室、不同麦克风)，可以在校对时把误删的改回保留；
- "识别置信度低""语速异常"很多：通常是录音质量差、背景音乐或回声大；
- "太短 / 太长"很多：说话停顿很少的话，可以在 config.yaml 里把 **max\_duration** 调到 15。

**问 提示"可用素材只有 X 分钟"或"英文素材不足 5 分钟"**

这是提醒：素材少也能训练，但效果会差一些。按 4.2、4.3 节补充素材。

**问 提示"去背景音乐需要安装 demucs"**

你勾选了"视频有背景音乐"，但没有安装 demucs 组件。建议取消勾选，改用 4.6 节的 UVR5 方法先分离人声。

**问 提示"没有挑到合适的参考音频"**

原因：没有找到 3.5~9.5 秒、完整一句话的片段。通常是素材太少，或者识别出的文字都没有句末标点。  
解决：增加素材；或者在校对时给句子补上句号、问号，保存后再生成。

## 15.4 训练阶段

**问 报错 "CUDA out of memory" (显存不足)**

解决：① 关闭其它占用显卡的程序 (游戏、剪辑软件、其它 AI 工具、浏览器里的视频)；② 在 **② 训练模型** 页面把 **batch** 改成 **2** (还不行改成 **1**) 再训练；③ 或者在 config.yaml 里把 **batch\_size: auto** 改成 **batch\_size: 2**。

**问 GTX 10 系列等老显卡训练报错，或者生成的声音全是杂音**

老显卡不支持半精度加速。在 config.yaml 里把 **is\_half: true** 改成 **is\_half: false**，重新启动程序后再训练。

**问 提示"没有检测到可用的 NVIDIA 显卡，训练会非常慢"**

原因：电脑没有 NVIDIA 显卡，或者驱动没装好。

解决：按 2.4 节更新驱动后重启电脑，再运行环境检查。没有 N 卡的电脑训练可能需要几天，建议借用一台有 N 卡的电脑训练，训练好后把两个文件夹复制回来使用 (13.6 节)。

**问 提示"GPT-SoVITS 环境有问题：缺少预训练模型……"**

按 3.6 节运行 **voicetwin.bat download-models --source hf-mirror** 补齐模型。

**问 提示"gsv\_s2\_train 失败（退出码 X）"或"1A 文本处理没有产出"**

训练的某一步出错了。错误信息下方会附上最后 30 行日志，常见原因：显存不足（见上）、硬盘空间不足（清理出 20GB 以上）、素材路径里有特殊字符。完整日志在 `D:\VoiceTwin\workspace\我的声音\logs` 里（附录 C）。

**问 训练到一半电脑睡眠 / 断电 / 不小心关掉了窗口**

重新打开程序，再点一次 **开始训练** 即可，从头开始训练。为避免这种情况，请按 8.1 节关闭自动睡眠。

**问 训练特别慢，进度很久不动**

SoVITS 每一轮可能需要几分钟到十几分钟（素材越多越久），进度按"轮"更新，所以会有一段时间不动。打开任务管理器 → 性能 → GPU，如果 GPU 使用率很高，说明正在正常训练，耐心等待即可。

## 15.5 生成阶段

---

**问 提示"GPT-SoVITS 推理服务启动失败"或"启动超时"**

解决：打开 `workspace\我的声音\logs\gptsovits_api.log`，看最后几行。常见原因：① 端口 9880 被占用（关闭其它 GPT-SoVITS 窗口，或者在 `config.yaml` 里把 `port` 改成 9881）；② 显存被其它程序占满；③ 模型文件不全（运行环境检查）。处理后关闭黑色窗口重新启动程序。

**问 提示"还没有训练好的 GPT-SoVITS 模型，暂时使用官方底模做零样本克隆"**

说明你还没有完成训练（或者训练失败），这时生成的声音只是"有点像"。请先完成第 8 章的训练。

**问 提示"讲稿里没有可以朗读的内容"**

讲稿为空，或者全部是代码块、图片、表情符号。检查讲稿内容；如果上传了文件，确认文件本身有文字（例如 Word 文档里的文字不是图片）。

**问 提示"读取 Word 讲稿需要：pip install python-docx"**

把 Word 讲稿另存为 .txt 再上传即可；或者重新运行一次最新版的安装程序（v0.1.1 起会自动安装 Word 支持）。

**问 上传讲稿文件后，生成的还是文本框里的旧内容 / 反过来**

上传了文件时以文件为准，文本框的内容会被忽略。想用文本框，先点上传区域右上角的 × 移除文件。

**问 生成的音频里某些句子有杂音、电流声、吞字、重复**

记下句子编号，用"只重新生成第几句"重做（9.5 节）；用 best 档会自动检查和重试。某一句反复出问题，改写这句话（拆短、换说法）。

**问 某个字 / 词总是读错**

写进读音纠正词典（10.4 节）。

**问 生成很慢**

第一次生成需要启动推理服务，多等 1 分钟是正常的。之后速度取决于档位：best 档每句生成 5 个版本还要识别检查，最慢。试听讲稿用 fast 档，正式生成再用 best 档。

## 15.6 效果问题

---

**问 声音不够像**

按 13.1 节的方法从上到下逐条尝试。其中增加素材、校对文字、剔除嗓子哑时的录音效果最明显。

**问 语速比我平时快 / 慢**

程序已经自动校准了语速。如果仍然觉得不对，用 `语速倍数` 调整（0.95 慢一点，1.05 快一点）。也可以在 [② 训练模型](#) 页面点 `重新挑选最佳模型`，重新校准一次。

**问 句子之间的停顿太长 / 太短**

停顿是按你素材里的习惯统计的。想整体调整，可以在 config.yaml 里把 `pauses` 改成 `fixed`，再修改 `fixed_pauses` 里的秒数（13.3 节）；个别位置用停顿标记（10.3 节）。

**问 英文有中文口音**

加入你讲英文的录音（至少 5~10 分钟），重新 ① 准备素材、② 训练。

**问 语气太平淡，没有讲课的感觉**

① 讲稿更口语化，多用问句、感叹句（10.8 节）；② 挑一条语气生动的参考音频指定使用（13.2 节）；③ 素材里多放一些你状态好、有激情的讲课录音。

**问 声音听起来有点闷 / 有点"电音"**

通常和素材质量有关：素材被压缩得很厉害、降噪太强。可以在 config.yaml 里把 `denoise` 改成 `off`，或者换用更清晰的原始录音，重新准备素材并训练。

## 15.7 其它问题

---

**问 我移动了 VoiceTwin 或 GPT-SoVITS 文件夹，现在打不开了**

重新运行一次 `install_windows.bat`，输入新的整合包路径。其它设置和 workspace 里的数据都会保留。

**问 如何升级到新版本**

从 Release 页面下载新版本的压缩包，解压后覆盖到 `D:\VoiceTwin`（选择"替换目标中的文件"），然后重新双击 `install_windows.bat`。你的 workspace、config.yaml 不会被覆盖（压缩包里不包含它们）。

### 问 如何卸载

① 在命令提示符运行 `D:\GPT-SoVITS\runtime\python.exe -m pip uninstall voicetwin`；② 删除 `D:\VoiceTwin` 文件夹（**workspace** 里有你的素材和生成的音频，需要的话先备份）；③ 删除桌面图标。GPT-SoVITS 整合包不需要的话也可以整个删除。

### 问 没有网络能用吗

安装、第一次准备素材（下载识别模型）、第一次使用 best 档需要联网下载。全部下载完成后，准备素材、训练、生成都可以离线进行。

## 15.8 如何收集信息并求助

如果以上方法都解决不了，请收集下面这些信息再求助（例如在项目的 GitHub 页面提交 Issue），能大大加快解决速度：

- 1 **环境检查结果**：在网页 [环境检查](#) 页面点检查，截图；或者在命令提示符运行 `voicetwin.bat doctor`，复制全部输出。
- 2 **出错时的完整信息**：网页日志或黑色窗口里的红色报错，截图或复制文字。
- 3 **详细错误信息**：用命令行重做出错的那一步，并在最后加上 `--verbose`，例如：  
`voicetwin.bat narrate -v 我的声音 D:\讲稿\第1课.md --verbose`
- 4 **日志文件**：`D:\VoiceTwin\workspace\我的声音\logs` 里对应的日志（附录 C 说明了每个日志的用途）。
- 5 **你的电脑配置**：显卡型号、显存、Windows 版本，以及声音分身的版本号（在 Release 页面或压缩包文件名里）。




提交日志或截图前，请检查里面有没有你不想公开的信息（例如讲课内容、个人姓名、文件路径里的真实姓名）。**不要上传你的素材音频或训练好的模型文件**，别人拿到它们就能模仿你的声音。

附录 A

# 日常使用速查卡

训练完成之后，日常使用只需要下面几步。可以把这一页打印出来贴在电脑旁边。

## A.1 生成一节课（5步）



## A.2 讲稿写法速查

| 想要的效果       | 写法                                                                       |
|-------------|--------------------------------------------------------------------------|
| 分段（段落停顿）    | 空一行                                                                      |
| 停顿 N 秒      | <code>[停顿=2]</code> 、 <code>[停顿=1.5]</code> 、 <code>[pause=800ms]</code> |
| 段落停顿（按你的习惯） | <code>[停顿]</code> 或 <code>[pause]</code>                                 |
| 提问语气        | 句末用问号 <code>？</code>                                                     |
| 感叹语气        | 句末用感叹号 <code>！</code>                                                    |
| 标题          | <code># 标题文字</code> （会读出来，前后停顿）                                          |
| 不读的内容       | 放在 <code>```</code> 代码块里                                                 |
| 纠正读音        | <code>workspace\我的声音\lexicon.txt</code> 里写 <code>原文 =&gt; 读法</code>      |
| 按视频时间轴配音    | 上传 <code>.srt</code> 字幕文件作为讲稿                                            |

## A.3 质量档位速查

| 档位       | 什么时候用     | 特点                      |
|----------|-----------|-------------------------|
| fast     | 检查讲稿、试听读音 | 每句 1 个版本，最快             |
| balanced | 日常使用      | 每句 3 个版本挑最像的            |
| best     | 正式发布的课程   | 每句 5 个版本，检查漏字错字，不合格自动重试 |

## A.4 相似度分数速查

| 声纹相似度            | 含义              |
|------------------|-----------------|
| $\geq 0.86$      | 非常像             |
| $0.78 \sim 0.86$ | 比较像             |
| $0.70 \sim 0.78$ | 有点像（建议重新生成这句）   |
| $< 0.70$         | 不太像（一定要重新生成或改写） |

## A.5 什么时候要重新训练

- ☐ 加入了新的讲课素材 → ① 准备素材 → ② 开始训练
- ☐ 校对 / 删除了片段 → 保存修改 → ② 开始训练
- ☐ 只是写了新讲稿、改了读音词典 → **不需要**重新训练，直接生成

## A.6 最常用的几条命令

| 做什么        | 命令（在 D:\VoiceTwin 打开命令提示符）                                                 |
|------------|----------------------------------------------------------------------------|
| 环境检查       | <code>voicetwin.bat doctor</code>                                          |
| 补齐预训练模型    | <code>voicetwin.bat download-models --source hf-mirror</code>              |
| 用讲稿文件生成    | <code>voicetwin.bat narrate -v 我的声音 D:\讲稿\第1课.md -q best</code>            |
| 只重做第 3、5 句 | <code>voicetwin.bat narrate -v 我的声音 D:\讲稿\第1课.md -q best --redo 3,5</code> |
| 替换视频的声音    | <code>voicetwin.bat mux --video 原视频.mp4 --audio 新音频.wav -o 新视频.mp4</code>  |
| 清空缓存       | <code>voicetwin.bat clear-cache -v 我的声音</code>                             |

## 附录 B

# 文件夹和文件说明

这一节列出声音分身会用到的所有文件夹和文件。一般不需要手动修改它们，了解它们有助于备份、排查问题。

## B.1 程序文件夹 D:\VoiceTwin

|                        |                         |
|------------------------|-------------------------|
| D:\VoiceTwin           |                         |
| ├─ install_windows.bat | 安装程序（双击运行）              |
| ├─ install_windows.ps1 | 安装程序的实际内容（被上面的 .bat 调用） |
| ├─ start_webui.bat     | 启动网页界面（安装后生成，桌面图标指向它）   |
| ├─ voicetwin.bat       | 命令行入口（安装后生成）            |
| ├─ config.yaml         | 设置文件（安装后生成，第 13.3 节）    |
| ├─ 使用教程（先看我）.html      | 网页版简明教程                 |
| ├─ README.md           | 项目说明                    |
| ├─ pyproject.toml      | 程序的版本和依赖信息              |
| ├─ docs\               | 文档（本手册 PDF 也在这里）        |
| ├─ voicetwin\          | 程序源代码（不要修改）             |
| └─ workspace\          | 你的数据（见 B.2）             |

## B.2 声音数据文件夹 workspace\我的声音

| 文件 / 文件夹         | 能否修改       | 内容                                    |
|------------------|------------|---------------------------------------|
| raw\             | 不要改        | 从你的视频里提取出的完整音频（每个素材文件一个 wav）。         |
| clips\           | 不要改        | 切好的一句一句的素材片段，训练用。                     |
| references\      | 可以试听       | 自动挑选的参考音频，文件名就是参考音频 id（13.2 节）。       |
| outputs\         | 可以删除       | <b>生成的音频、字幕、报告。</b>                   |
| cache\           | 可以清空       | 句子缓存和声纹缓存（用 clear-cache 命令清空，13.6 节）。 |
| logs\            | 可以查看       | 各步骤的日志（附录 C）。                         |
| exports\、models\ | 不要改        | 交给 GPT-SoVITS 训练用的文件列表和配置。            |
| transcripts.csv  | <b>可以改</b> | 校对表，可用 Excel / WPS 打开修改（7.3 节）。       |
| lexicon.txt      | <b>可以改</b> | 读音纠正词典（10.4 节）。                       |
| manifest.jsonl   | 不要改        | 所有片段的详细信息（文字、时长、是否保留等）。               |
| references.json  | 可以查看       | 参考音频列表（id、文字、语言、类型）。                  |

| 文件 / 文件夹               | 能否修改 | 内容                            |
|------------------------|------|-------------------------------|
| profile.json           | 可以查看 | 你的说话风格：语速、停顿、音高、响度的统计。        |
| models.json            | 不要改  | 训练结果：模型文件列表、自动挑选的最佳模型、语速校准系数。 |
| sources.json           | 不要改  | 处理过的素材文件记录（用于下次只处理新文件）。       |
| prepare_summary.json   | 可以查看 | 最近一次素材准备的摘要。                  |
| speaker_centroid.*.npy | 不要改  | 你的"平均声纹"，用于过滤素材和打分。           |

### B.3 GPT-SoVITS 整合包里与你相关的文件

| 位置                                               | 内容                         |
|--------------------------------------------------|----------------------------|
| D:\GPT-SoVITS\SoVITS_weights_v2ProPlus\vt_...pth | 训练好的音色模型（多个版本）。            |
| D:\GPT-SoVITS\GPT_weights_v2ProPlus\vt_...ckpt   | 训练好的语气节奏模型（多个版本）。          |
| D:\GPT-SoVITS\logs\vt_...\                       | 训练的中间文件，训练完成后可以删除（13.6 节）。 |
| D:\GPT-SoVITS\GPT_SoVITS\pretrained_models\      | 官方预训练模型（底模），不要删除。          |



文件名里的 vt\_ 表示由声音分身训练；后面跟着声音名称里的英文部分和一段编号，用来区分不同的声音。

附录 C

# 日志文件说明

所有日志都在 `D:\VoiceTwin\workspace\我的声音\logs` 里，可以用记事本打开，最新的内容在文件末尾。

| 日志文件                                                           | 对应步骤           | 什么时候看                      |
|----------------------------------------------------------------|----------------|----------------------------|
| <code>prepare.log</code>                                       | ① 准备素材         | 素材准备报错、保留的片段太少时。           |
| <code>voicetwin.log</code>                                     | 训练、挑选模型、生成     | 总日志，大部分问题先看这里。             |
| <code>gsv_1a_text.log</code>                                   | 训练 1A 文本处理     | 提示"1A 文本处理没有产出"时。          |
| <code>gsv_1b_hubert.log</code> 、<br><code>gsv_1b_sv.log</code> | 训练 1B 特征提取     | 1B 阶段报错时。                  |
| <code>gsv_1c_semantic.log</code>                               | 训练 1C 语义 token | 1C 阶段报错时。                  |
| <code>gsv_s2_train.log</code>                                  | 训练音色模型 SoVITS  | SoVITS 训练报错（如显存不足）时。       |
| <code>gsv_s1_train.log</code>                                  | 训练语气节奏模型 GPT   | GPT 训练报错时。                 |
| <code>gptsovits_api.log</code>                                 | 生成时的推理服务       | "推理服务启动失败 / 超时"、生成报错时。     |
| <code>qwen3tts_worker.log</code> 等                             | 可选引擎           | 使用 Qwen3-TTS、IndexTTS 报错时。 |

 日志很长时，按 `Ctrl + End` 跳到文件末尾，从下往上找 `Error`、`Traceback`、`错误`、`失败` 等字样，通常就是问题所在。

## 附录 D

# 隐私、安全与合规使用

---

## D.1 你的数据留在你的电脑上

---

- 声音分身的所有处理（识别、训练、生成）都在**你自己的电脑上**完成，素材、模型和生成的音频不会上传到任何服务器。
- 联网只用于：下载程序和组件、下载开源模型（识别模型、预训练模型）。
- 网页界面默认只允许本机访问（127.0.0.1）。

## D.2 保护好你的声音模型

---

- 训练好的模型文件和素材，别人拿到就可以模仿你的声音。**不要把它们上传到网盘公开分享，也不要发给不信任的人。**
- 不要使用 `--share` 生成公网链接（13.7 节）。
- 不再使用某个声音时，可以删除 `workspace` 里对应的文件夹和整合包里 `vt_` 开头的模型文件。

## D.3 合规使用

---



### 请务必遵守

- ① **只克隆你自己的声音**，或者已经取得本人**明确书面授权**的声音。
- ② **不得**用于冒充他人、诈骗、诽谤、制造虚假信息等违法用途。
- ③ 在公开平台发布 AI 合成的音频或视频时，请遵守**平台规则和所在地区关于 AI 生成内容标识的规定**（例如在视频简介或画面中注明"本视频配音由 AI 合成"），并以相关规定的最新要求为准。

用自己的声音、为自己的课程生成讲解，是这个工具设计的初衷。为了对学生负责，建议在课程介绍中说明部分讲解音频由你本人声音的 AI 模型生成、内容由你本人撰写和审核。

附录 E

# 版本信息与致谢

## E.1 本手册对应的版本

| 项目   | 内容                                                                                                                                |
|------|-----------------------------------------------------------------------------------------------------------------------------------|
| 程序   | 声音分身 VoiceTwin <b>v0.1.2</b> (Windows 版)                                                                                          |
| 下载地址 | <a href="https://github.com/AlienCodes/literate-enigma/releases/latest">github.com/AlienCodes/literate-enigma/releases/latest</a> |
| 默认引擎 | GPT-SoVITS v2ProPlus                                                                                                              |
| 手册日期 | 2026 年 9 月                                                                                                                        |

## E.2 更新记录

| 版本     | 主要内容                                                                             |
|--------|----------------------------------------------------------------------------------|
| v0.1.2 | 新增 4 页的《快速上手》(PDF 和网页版)，压缩包里的"使用教程 (先看我)"也换成了快速上手。                               |
| v0.1.1 | 新增本 PDF 使用手册；评估结果改为中文结论，不再误报"异常停顿"；参考音频不再重复；安装程序支持 Word 讲稿；移动整合包或换电脑后自动找回训练好的模型。 |
| v0.1.0 | 第一个 Windows 发布版：素材准备、自动校对表、GPT-SoVITS 训练与自动挑选最佳模型、语速校准、讲稿生成、评估、网页界面、一键安装程序。      |

## E.3 致谢

声音分身建立在许多优秀的开源项目之上，感谢它们的作者。各项目遵循其各自的开源许可证；使用预训练模型时，请同时遵守对应模型的许可条款。

| 项目                               | 用途                    |
|----------------------------------|-----------------------|
| GPT-SoVITS                       | 声音克隆训练与合成 (默认引擎)      |
| faster-whisper / Whisper、FunASR  | 中英文语音识别               |
| Resemblyzer                      | 声纹相似度计算               |
| Qwen3-TTS、IndexTTS               | 可选合成引擎                |
| FFmpeg、librosa、pyloudnorm、Gradio | 音视频处理、音频分析、响度标准化、网页界面 |