

声音分身 VoiceTwin 快速上手

只讲最重要的，10 分钟看完。一共三件事：安装（一次）→ 训练你的声音（一次）→ 生成讲课音频（以后每次）。

准备

- Windows 10 / 11 电脑，**NVIDIA 显卡**（显存 6GB 以上），D 盘空出 **30GB**
- 你以前录的**讲课视频**（嗓子正常时录的，**30 分钟以上**，1~3 小时最好）
- 解压软件 **7-Zip**：打开 <https://www.7-zip.org/>，点第一个 Download，安装

已经装过旧版本？升级只要 3 步，声音和训练好的模型都不会丢：① 下载新的 VoiceTwin-Windows-v...zip，右键 → 全部解压缩 → 位置填 D:\，提示有同名文件时选**替换**；② 双击 D:\VoiceTwin\install_windows.bat，输入 1，再输入 D:\GPT-SoVITS；③ 看到 "**✓ 安装成功！**" 后，它会问"现在就打开声音分身吗？"，直接按回车就会打开，网页标题里显示新版本号就对了。

一、安装（只做一次，约 30~60 分钟）

第 1 步 下载两个东西

- 声音分身：打开 <https://github.com/AlienCodes/literate-enigma/releases/latest>，点 VoiceTwin-Windows-v...zip 下载
- GPT-SoVITS 整合包：打开[官方下载页](#)，下载**最新的 v2pro 整合包**（.7z 文件，好几个 GB；RTX 50 系列显卡选文件名带 nvidia50 的）

第 2 步 解压到 D 盘

- 整合包：右键 → 7-Zip → 解压，把解压出来的文件夹改名为 **GPT-SoVITS**，放到 D 盘，也就是 D:\GPT-SoVITS
- 声音分身：右键 → 全部解压缩 → 位置填 **D:**，得到 **D:\VoiceTwin**

第 3 步 运行安装程序

1. 双击 `D:\VoiceTwin\install_windows.bat`
2. 问"请输入 1 或 2": 输入 `1` , 按回车
3. 问"整合包路径": 输入 `D:\GPT-SoVITS` , 按回车 (如果显示"找到了整合包: D:\GPT-SoVITS", 直接按回车就行)
4. 等它自己装完 (窗口里滚动英文是正常的, **别关闭窗口**), 看到 " **安装成功!**" 后, 它会问"现在就打开声音分身吗?", 按回车就会打开
5. 桌面出现 "**声音分身 VoiceTwin**" 图标 = 装好了 

如果安装最后的检查里有  "缺少预训练模型": 先按第 5 步打开程序, 点  **环境检查** 页面的  **下载** 缺少的模型, 等进度条走到 100% 即可。

二、训练你的声音（只做一次，电脑自动完成，约 1~3 小时）

第 4 步 放素材: 在 D 盘新建文件夹 **讲课素材** , 把你以前的讲课视频复制进去。

第 5 步 打开程序, 先看显卡: 双击桌面 "**声音分身 VoiceTwin**", 等浏览器自动打开 (**黑色窗口不要关, 最小化就行**)。

页面最上面有一条**显卡状态**, 一直显示着:

-  **绿色**  **显卡正常** = 一切正常, 继续往下做
-  **红色**  **显卡没有正常工作** = 先照着红条里"怎么办"做 (一般是到 [NVIDIA 官网](#) 装最新显卡驱动, **重启电脑**), 再点右边  **重新检查显卡**

 **显卡正常: NVIDIA GeForce RTX 4070 (显存 12.0 GB, 可用 10.5 GB)**

 **重新检查显卡**

第 6 步 准备素材

1. 最上面 **声音名称** 输入: `我的声音`
2. 在 ① **准备素材** 页面, "或者填写电脑上的文件夹路径"里填: `D:\讲课素材`
3. 点橙色按钮 **开始准备素材**

声音分身 VoiceTwin v0.1.6

用自己的讲课视频/录音，复刻你的音色、语气和节奏（中文 + 英文）。按 ① → ② → ③ 的顺序操作就行。

✅ 显卡正常：NVIDIA GeForce RTX 4070（显存 12.0 GB，可用 10.5 GB）

🔄 重新检查显卡

声音名称（新建请直接输入名字）

我的声音

🔄 刷新声音列表

「我的声音」是新声音，还没有素材。👉 下一步：在「① 准备素材」里填讲课视频所在的文件夹，点「开始准备素材」。

🔊 我的声音库（共 0 个）

① 准备素材 ② 训练模型 ③ 生成讲课音频 ④ 试试像不像（可选） ⑤ 鉴别 🔍 环境检查

上传你的讲课视频或录音（越多越好，建议总时长 ≥30 分钟，1~3 小时最佳；只要你本人说话的部分）。如果视频有同名 .srt 字幕，也一起放进去，会直接用字幕的文字，更准确。

📁 上传视频/音频/字幕（可多选）

📁
将文件拖放到此处
- 或 -
点击上传

或者填写电脑上的文件夹路径（推荐）

视频很大（几个 GB）时，建议直接填文件夹路径，不用上传，更快，也不占 C 盘。

D:\讲课素材

☐ 视频有背景音乐（去除背景音乐，会慢一些）

高级设置（一般不用改）

开始准备素材

4. 下面会出现**进度条**，显示做到百分之几、第几步、已经用了多久、**大约几点做完**：

-  **绿色** = 正在正常工作，等着就行
-  **黄色** = 已经好几分钟没有新进度（第一次会下载识别模型，慢一点是正常的，先耐心等待）
-  **红色** = 出问题停下了，照着红条里的"怎么办"做
-  **走到 100%、显示"全部完成"** = 做好了

● 正在准备素材.....（绿色条纹在动，说明程序在正常工作）

第 2 步（共 7 步）：提取声音、降噪、切成小段

30%

第 3 / 3 个文件，已用 50 秒，这一步不到 1 分钟就好

🕒 全部大约还要 2 分钟，预计 13:47 左右完成

现在：[第 3/3 个文件] 降噪、统一音量

可以去做别的事，但不要关闭运行程序的窗口。

5. 完成后下面会列出所有片段，每行**前面有编号**，表格上方写着**一共多少条、保留多少条（多少分钟）**

第 6½ 步 找错字（推荐，5 分钟）

- 1. 点 🔍 自动查找可能的错字，等进度条走完
- 2. 勾选 只看可能有错的：可能识别错的字会用红色标出来，旁边写着建议
- 3. 点某一行可以试听；建议对就点 ✅ 采用建议，或者双击"文字"格子自己改
- 4. 改完点 保存修改

一共 228 条片段：保留 228 条（16.4 分钟），不保留 0 条，其中 2 条可能有错（已标红）

英文 60 条，中文 168 条；其中 20 条留作「考试题」（用来自动挑选最像你的模型）

🔍 自动查找可能的错字

☒ 只看可能有错的

🔄 重新载入

✅ 全部完成！用时 0 秒

100%

「查找可能的错字」已经做好了 · 完成时间 13:45

✅ 检查完了：一共查了 228 条，其中 2 条可能有错（已在表格里标红）

按规则检查了 228 条（没有可用的第二个识别引擎，能发现的错字比较少）。
勾选「只看可能有错的」，可以只看标红的片段；点某一行能看到两次识别的对比，有建议时可以点「✅ 采用建议」。

#	id	保留 (是/ 否)	语言	秒	文字	可能有错（红色）	丢弃原因
1	第1课_0114c2_0001	是	中文	4.9	今天我们来学习 VFIXED 里面的列表推导式。	今天我们来学习 VFIXED 里面的列表推导式。	
2	第1课_0114c2_0003	是	中文	4	首先我们来看看一个最简单简单的例子。	首先我们来看看 看看 一个最简单简单的例子。	

🔊 试听：第 1 条 今天我们来学习 VFIXED 里面的列表推导式。

0:04

🔊 1x

⏮ ⏪ ⏸ ⏩ ⏭

0:05

⚠️ 可能有错：「VFIXED」像是听错的英文（不是常见的缩写）

识别 A（现在的文字）：今天我们来学习 **VFIXED** 里面的列表推导式。

识别 B：（没有建议。请听一听录音，有错就直接在「文字」列里改）

第 7 步 训练

- 1. 点 ② 训练模型 页面，什么都不用改：电脑会按你的显卡自动定好最合适的训练参数（页面上会写出来）
- 2. 点橙色按钮 开始训练，等进度条走到 100%、显示 ✅ 训练完成
- 3. 训练期间别关电脑、别让电脑睡眠（程序会尽量让电脑不睡眠，保险起见：设置 → 系统 → 电源 → 睡眠改成"从不"）

三、生成讲课音频（以后每次只做这 4 步）

第 8 步 双击桌面图标，在 **声音名称** 选 **我的声音**（或者在  **我的声音库** 里点一下它），点 **③ 生成讲课音频**

第 9 步 把讲稿**粘贴**到"讲稿"框里（或者在下面上传 txt / Word 文件）

第 10 步 设置，然后点橙色按钮 **生成**

- **质量**：电脑会按你的显卡自动选好，**显卡正常时默认就是「完美」**（每句最多试 20 次，挑最像你的，最慢）。只想先快速听个效果，可以选「均衡」
- **语速**：拉杆在 **0 = 和你原声一样**；往左拉更快，往右拉更慢，声音不会变。点 **▶ 试听语速** 先听一句（建议在 -15~+15 之间）

讲稿

第四课：生成器表达式
大家好，欢迎回来。上节课我们学习了列表推导式，今天我们来学习生成器表达式。
它的写法和列表推导式几乎一样，只是把中括号换成了小括号。那么它们有什么区别呢？[停顿=1.5]
最大的区别在于，生成器不会一次性把所有结果都放进内存。
Let's look at a quick example. 好，我们一起来看一个例子。

或上传讲稿文件 (txt / docx / md / srt)

↑

将文件拖放到此处
- 或 -
点击上传

保存的文件名 (可以不填)
例如：第3课 牛顿第二定律

保存格式

☒ WAV (音质最好，剪辑/后期用)

☐ MP3 (文件小，方便发微信、上传)

质量

☐ 快速 (最快，每句只做 1 遍)

☐ 均衡 (每句做 3 遍，挑最像你的)

☐ 最好 (每句做 5 遍，并检查漏字错字)

☐ 极致 (很慢，更稳更像，建议显存 ≥ 8GB)

完美：每句最多试 20 次、严格检查漏字错字，同时做「未去杂音 / 去杂音」两个版本让你选，句子之间完全静音，尽最大可能接近你本人 (最慢)

越往下越慢，但每句会多试几次，自动挑最像你的，结果更稳定。不会 100% 一模一样：素材的质量和数量、认真校对文字，对像不像影响最大。
已按你的显卡自动选好「完美」(显存 12 GB)。

语速 (← 往左更快 · 中间 0 = 和你原声一样 · 往右 0 更慢 →)

当前：和你原声一样 语速调得越极端 (超过 ±20%)，越可能不自然；建议在 -15~+15 之间。

▶ 试听语速

只重新生成第几句 (例如 3,5,8-10；留空 = 全部)

高级设置 (一般不用改)

生成

第 11 步 等进度条走到 100%，然后：

- 表格里每一句都有 **"像你本人 (%)"**，有一句不够像会标出来
- **「完美」档**会做两个版本：**A 未去杂音**、**B 去杂音**。电脑会自动比较哪个更像你，标 **★** 推荐。两个都听一听，在 **最终使用哪个版本** 里选你喜欢的
- 生成的声音**只有你的声音**：没有背景音、没有底噪，句子之间的停顿是**完全静音**

🔊 这次做了两个版本，听一听，选你更喜欢的

1. 版本 A：未去杂音（像你本人 69.1%） ★ 推荐：更像你的原声
2. 版本 B：去杂音（像你本人 69.1%）

★ 推荐：版本 A，更像你的原声（两个版本几乎一样像，听哪个顺耳就用哪个）

两个版本的文字、停顿和字幕完全一样，只是 B 去掉了轻微的杂音。相似度是声纹模型自动打分，越高越像，但不是绝对精确，最终以耳朵为准。

🔊 版本 A：未去杂音（像你本人 69.1%）



0:00 0:42

🔊 1x

🔊 版本 B：去杂音（像你本人 69.1%）



0:00 0:42

🔊 1x

最终使用哪个版本

☒ 版本 A：未去杂音 ☐ 版本 B：去杂音

点 ▶ 试听；在"下载（音频 / 字幕）"里点文件名后面的大小（如 2.1 MB ↓）下载 音频（.wav）和 字幕（.srt），直接拖进剪映用

📁 下载（音频 / 字幕）

第四课_生成器表达式_10月01日14点19分.wav	2.5 MB ↓ ×
第四课_生成器表达式_10月01日14点19分.srt	682.0 B ↓ ×
第四课_生成器表达式_10月01日14点19分_未去杂音.wav	2.5 MB ↓ ×
第四课_生成器表达式_10月01日14点19分_去杂音.wav	2.5 MB ↓ ×

生成的文件也会自动保存在 D:\VoiceTwin\workspace\我的声音\outputs 文件夹里。

某几句不满意？看表格里这句的编号，在"只重新生成第几句"里填编号（例如 3,5 ），再点 生成，只重做这几句，很快。

想确认像不像？（可选）⑤ 鉴别 页面：点 开始鉴别，电脑给每个生成的音频打分、排名（低于 85% 的会标出来）；点 生成盲听测试，可以让同事、学生听，看他们能不能分出哪段是真人。

讲稿怎么写（记住 3 条就够）

1. 标点写对：问句用问号，模型就会用提问的语气
2. 空一行 = 换一段，停顿会稍长一点
3. 想停几秒，就写 [停顿=2] （停 2 秒）

遇到问题

问题	怎么办
双击 install_windows.bat 窗口一闪就没了	在 install_windows.ps1 上右键 → 使用 PowerShell 运行

问题	怎么办
桌面上没有出现图标	在 D:\VoiceTwin 里右键 start_webui.bat → 发送到 → 桌面快捷方式（或者直接双击 start_webui.bat）
页面最上面是红色"✗ 显卡没有正常工作"	到 NVIDIA 官网 装最新显卡驱动， 重启电脑 ，再点  重新检查显卡（不装好训练会非常慢）
进度条变成红色	看红条里的"原因"和"怎么办"照着做；需要别人帮忙时，点开下面"详细过程"，把内容复制给他
进度条变成黄色很久不动	先等几分钟（下载模型、处理很长的视频时会这样）；超过半小时还不动，点 ■ 停止（5 秒内点两次），再重新点开始
浏览器没有自动打开	自己打开浏览器，地址栏输入 127.0.0.1:7860 回车
训练时提示显存不够（out of memory）	程序会自动减小设置重试；还不行就在 ② 训练模型 → 高级设置 把"每批数量"改成 2，再点开始训练
某个字总是读错	用记事本打开 D:\VoiceTwin\workspace\我的声音\lexicon.txt，加一行 行长 => 航长（原文 => 读法），保存后重新生成
声音不够像	多放一些讲课视频（1~3 小时），删掉嗓子哑时的录音，做一次"找错字"，重新做第 6、7 步

其它问题：把红色进度条里的"原因"和"怎么办"，以及下面"详细过程"里的文字截图或复制下来，发给帮你的人。

只克隆你自己的声音。公开发布 AI 合成的音频时，请按平台规定标注"AI 合成"。